Büyük Dil Modellerinde Maliyet-Etkin İstem Yönlendirmenin Bilgi Kuramı ve Sözcüksel-Semantik Karmaşıklık Özniteliklerine Dayalı Açıklanabilir Hibrit Model ile Tahmini

Explainable Hybrid Model Based on Information-Theoretic and Lexical-Semantic Complexity Features for Cost-Efficient Prompt Routing in Large Language Models

Yazar: Emin Burak Öztürk

Kurum: Balıkesir Üniversitesi, Balıkesir Meslek Yüksekokulu, Yapay Zeka Operatörlüğü Programı, Balıkesir, Türkiye

E-posta: eminburak1410@gmail.com

Veri Seti: LMSYS / UC Berkeley RouteLLM Kıyaslama Veri Seti (routellm_berkeley_dataset.csv — Toplam N = 119.101 İstem: train.jsonl N_(train) = 109.101 Eğitim + valid.jsonl N_(test) = 10.000 Resmi Test)

Resmi Veri Seti Bağlantısı (URL): https://huggingface.co/datasets/routellm/gpt4_dataset/tree/main

ÖZET

Amaç

Büyük Dil Modellerinin (LLM) kurumsal ve endüstriyel dağıtımlarında, en yetenekli ticari modellere (örn. GPT-4) yönelik API çağrı maliyetleri ölçeklenebilirlik önünde kritik bir ekonomik darboğaz oluşturmaktadır. Buna karşılık, açık ağırlıklı ekonomik modeller (örn. Mixtral-8x7B) rutin istemler için yeterli kalite sunmasına rağmen, yüksek muhakeme gerektiren karmaşık istemlerde başarısız olabilmektedir. Bu çalışmanın temel amacı; kullanıcı istemlerini daha model çıkarımı gerçekleşmeden önce yüzeysel morfolojik, sözdizimsel, bilgi kuramı (Shannon Entropisi, Öz-Bilgi, Koşullu Entropi, Karşılıklı Bilgi, Bilgi Kazancı ve Göreceli Entropi / KL-Diverjans), okunabilirlik ve denetimli sözcüksel-semantik görev karmaşıklığı boyutlarında analiz ederek, açık ağırlıklı küçük modelin kalite çöküşü yaşama riskini (Y = I(S_(Mixtral) ≤ 3)) milisaniye altı CPU çıkarımıyla tahmin eden, olasılık kalibrasyonlu, maliyet-etkin ve Açıklanabilir Hibrit Yapay Zeka (**RouteCost-XAI**) mimarisi geliştirmektir.

Yöntemler

UC Berkeley LMSYS RouteLLM kıyaslama veri tabanının (https://huggingface.co/datasets/routellm/gpt4_dataset/tree/main) hem eğitim (train.jsonl, N_(train) = 109.101) hem de resmi test (valid.jsonl, N_(test) = 10.000) kümeleri tekil bir veri yapısında (routellm_berkeley_dataset.csv, N = 119.101) birleştirilmiştir. Veri sızıntısını (data leakage) kesin olarak engellemek üzere **4 aşamalı ayrık bölümleme (4-way leak-free split)** uygulanmıştır:

1. n_(train) = 12.000 aktif model eğitim kümesi (train.jsonl),

2. n_(val) = 3.000 ayrık doğrulama kümesi (Platt kalibrasyonu, SLSQP ağırlıkları ve τ* eşik seçimi için, train.jsonl),

3. N_(bg) = 94.101 ayrık arka plan eğitim derlemi (TF-IDF, NBSVM ve Ridge projeksiyonlarının eğitimi için, train.jsonl),

4. N_(test) = 10.000 **Resmi valid.jsonl Test Kümesinin tamamı** (hiçbir öğrenme, kalibrasyon veya eşik seçiminde dokunulmamış bağımsız test).

Küçük model kalite puanı (S_(Mixtral) □ [1, 5]) temel alınarak hem ayrık belleksiz kaynak (DMS) öz-bilgi ($I(s_i) = \log_2(1/P(s_i))$) analizi hem de ikili yönlendirme hedefi (S ≤ 3: Karmaşık Rota/GPT-4 şart, Y = 1; S ≥ 4: Ekonomik Rota/Mixtral yeterli, Y = 0) tanımlanmıştır. 5 katmanlı ve 26 boyutlu sızıntısız öznitelik uzayı geliştirilmiştir; ilk 24 öznitelik salt matematiksel metin formülleri, son 2 öznitelik ise arka plan eğitim derleminden öğrenilen ortogonal N-gram log-olasılık (lexical_log_odds) ve kalite açığı (semantic_deficit_score) projeksiyonlarıdır. Özniteliklerin normallik varsayımları Shapiro-Wilk, Martinez-Iglewicz ortanca normallik testi, Anderson-Darling ve D'Agostino testleriyle; aykırı değer yapıları Z-skoru (|Z|>3) ve kutu grafikleriyle; bağımlılıkları Kovaryans, Pearson (r), Spearman (ρ) ve ardışık Varyans Şişme Faktörü (VIF < 5.0) ile denetlenmiştir. Sınıflandırma aşamasında **20 makine öğrenmesi modeli**, RouteLLM referans yönlendiricileri (Matris Ayrıştırma ve SW-Ranking) ve sürekli kalite tahmininde **4 regresyon modeli** kıyaslanmıştır. Dört temel ağaç ailesi modeli (CatBoost %24, XGBoost %18,

LightGBM %8, Extra Trees %50) katman dışı Platt Sigmoid kalibrasyonuna tabi tutularak simpleks kısıtlı SLSQP optimizasyonuyla birleştirilmiştir.

Bulgular

Geliştirilen RouteCost-XAI Ağırlıklı Hibrit Modeli; resmi valid.jsonl test kümesinin tamamında (N = 10.000) **0.7689 ROC-AUC**, **0.3981 PR-AUC**, **0.4032 F1-Skoru**, **0.8194 Doğruluk**, **0.4508 Duyarlılık**, **0.8771 Özgüllük**, **0.0999 Brier Skoru**, **0.3351 Log-Loss**, **0.6753 Normalize AIC**, **5006.5 bit MDL** ve **0.1806 Karar Kanalı Hata Oranı (BER)** elde ederek incelenen 19 karşılaştırma modelini (en yakın tekil model CatBoost'a karşı +0.0006 ROC-AUC, Wilcoxon $p < 0.001$) ve görev proxy hedefine uyarlanmış RouteLLM referans yönlendiricilerini (Matris Ayrıştırma: 0.7227 ROC-AUC, SW-Ranking: 0.7139 ROC-AUC) geride bırakmıştır. Ayrık doğrulama kümesinde (n=3.000) belirlenen optimal karar eşiğinde ($\tau^* = 0.22$), istemlerin **%16.73'ü** büyük modele yönlendirilerek simüle edilen 1 milyon istemlik maliyet-kalite modelinde (17.000,00 USD GPT-4 vs 240,00 USD Mixtral) **%82.09 net API maliyet tasarrufu**, **%40.82 APGR** (eş-bütçeli RouteLLM Matris Ayrıştırma %39.47 ve SW-Ranking %19.07 referanslarının üzerinde), **%45.08 Kümülatif Kazanç (Gain)** ve **2.69x Kaldırma (Lift) Çarpanı** sağlanmıştır. Dört ağacın SLSQP ağırlıklarıyla birleştirilen TreeSHAP ve uzunluk-stratifiye entropi analizleri; yüzeysel metin uzunluğunun tek başına yetersiz bir vekil olduğunu, sözcüksel-semantik projeksiyonların ve bilgi kuramı metriklerinin (H(X), IG, D(p|| q)) istem uzunluğu kontrol edildiğinde dahi ($p < 10^{-10}$) anlamlı tamamlayıcı ayrım gücü sunduğunu kanıtlamıştır.

Sonuç

RouteCost-XAI mimarisi, bilgi kuramı özniteliklerini ve sözcüksel-semantik karmaşıklık projeksiyonlarını kalibre edilmiş hibrit ağaç topluluklarıyla birleştirerek, endüstriyel LLM dağıtımlarında operasyonel maliyetleri düşüren, donanım dostu (vektörel ağaç tahmini **0.014 ms**, uçtan uca tekil istem çevrimiçi CPU çıkarımı **84.71 ms**) ve tam denetlenebilir bir yönlendirme çerçevesi sunmaktadır.

Anahtar Kelimeler

Büyük Dil Modelleri; İstem Yönlendirme; Bilgi Kuramı; Shannon Entropisi; Sözcüksel-Semantik Karmaşıklık; KL-Diverjans; Önyargı-Varyans Dengesi; AIC/BIC/MDL Model Seçimi; Açıklanabilir Yapay Zeka (TreeSHAP); Hibrit Topluluk Öğrenmesi.

ABSTRACT

Objective

In enterprise deployments of Large Language Models (LLMs), API invocation costs of frontier commercial models (e.g., GPT-4) constitute a major financial bottleneck. While lightweight open-weights models (e.g., Mixtral-8x7B) satisfy routine queries, they frequently fail on complex reasoning tasks. This study develops a calibrated, cost-efficient, and Explainable Hybrid Artificial Intelligence (**RouteCost-XAI**) architecture combining information-theoretic and lexical-semantic complexity features to predict small-model quality collapse risk ($Y = I(S_(Mixtral) \leq 3)$) and route user prompts with sub-millisecond CPU tree inference.

Methods

Both the official training split (train.jsonl, $N_(train) = 109{,}101$) and the official unseen test split (valid.jsonl, $N_(test) = 10{,}000$) from the UC Berkeley LMSYS RouteLLM benchmark (https://huggingface.co/datasets/routellm/gpt4_dataset/tree/main) were integrated into a unified dataset (routellm_berkeley_dataset.csv, N = 119,101). A strict 4-way leak-free split was enforced: $n_(train) = 12{,}000$ active training set, $n_(val) = 3{,}000$ disjoint validation set for calibration and threshold tuning, $N_(bg) = 94{,}101$ background training set for lexical projections, and $N_(test) = 10{,}000$ comprising 100% of the official unseen test set. A 5-tier, 26-dimensional pure-prompt feature space was engineered incorporating Discrete Memoryless Source (DMS) self-information $I(x) = \log_2(1/P(x))$, Shannon Entropy H(X), Conditional Entropy H(Y|X), Mutual Information / Information Gain IG(Y,X), asymmetric Kullback-Leibler Divergence D(p|| q), Lempel-Ziv (Gzip) source coding ratio, Signal-to-Noise Ratio (SNR_(dB)), and orthogonal N-gram log-odds and semantic deficit projections fitted strictly on the background training corpus. Normality (Shapiro-Wilk, Martinez-Iglewicz, Anderson-Darling, D'Agostino), outliers (Z-score, Box-Plot), covariance/correlation (Pearson r, Spearman ρ, iterative VIF < 5.0), unsupervised clustering (K-Means Elbow, Silhouette, exact Dunn Index), and hyperparameter search strategies (Grid,

Random, Coarse-to-Fine, Gaussian Process Bayesian Optimization with Expected Improvement) were evaluated. **Twenty classification models**, adapted RouteLLM reference routers (Matrix Factorization and Similarity-Weighted Ranking), and **four continuous regression models** (evaluated via MSE, RMSE, MAE, RMSLE, R^2, Adjusted R^2) were benchmarked. The four constituent tree ensembles (CatBoost 24%, XGBoost 18%, LightGBM 8%, Extra Trees 50%) were calibrated via Platt Sigmoid on out-of-fold predictions and ensembled using simplex-constrained SLSQP optimization.

Results

On 100% of the official unseen valid.jsonl test set (N = 10,000), the proposed RouteCost-XAI Hybrid Model achieved **0.7689 ROC-AUC**, **0.3981 PR-AUC**, **0.4032 F1-score**, **0.8194 Accuracy**, **0.4508 Sensitivity/Recall**, **0.8771 Specificity**, **0.0999 Brier Score**, **0.3351 Log-Loss**, **0.6753 Normalized AIC**, **5006.5 bits MDL**, and **0.1806 Bit Error Rate (BER)**, outperforming the 19 classical/ensemble baselines (+0.0006 ROC-AUC over CatBoost, Wilcoxon $p < 0.001$) as well as adapted RouteLLM reference routers (Matrix Factorization: 0.7227 ROC-AUC; SW-Ranking: 0.7139 ROC-AUC). At the validation-learned optimal threshold ($\tau^* = 0.22$), routing **16.73%** of prompts to the frontier model achieved **82.09% net API cost reduction**, **40.82% simulated APGR** (surpassing iso-budget Matrix Factorization at 39.47% and SW-Ranking at 19.07%), **45.08% Cumulative Gain**, and **2.69x Lift** with a vectorized tree inference time of **0.014 ms** (84.71 ms median end-to-end single-prompt CPU latency including feature extraction). Length-stratified entropy and TreeSHAP analyses demonstrated that surface prompt length alone is an insufficient proxy, while lexical-semantic projections and information-theoretic features provide statistically significant discriminative power across all length strata ($p < 10^{-10}$).

Conclusion

RouteCost-XAI demonstrates that combining lexical-semantic complexity projections, information-theoretic metrics, and calibrated ensemble learning yields an interpretable, lightweight, and cost-effective framework for LLM query routing.

Keywords

Large Language Models; Prompt Routing; Information Theory; Shannon Entropy; Lexical-Semantic Complexity; KL-Diverjans; Bias-Variance Trade-off; AIC/BIC/MDL; Explainable AI (TreeSHAP); Hybrid Ensemble Learning.

GİRİŞ

Yapay zeka alanında son yıllarda yaşanan en büyük paradigma değişimi, milyarlarca parametreye sahip Büyük Dil Modellerinin (LLM) genel amaçlı problem çözme yetenekleriyle ortaya çıkmasıdır (1,2). Ancak bu modellerin endüstriyel, kurumsal ve kamu sistemlerine entegrasyonu, daha önce benzeri görülmemiş bir hesaplama maliyeti, bellek tüketimi ve enerji darboğazını da beraberinde getirmiştir (2,3). Günümüzde OpenAI GPT-4, Anthropic Claude 3.5 Sonnet ve Google Gemini Pro/Ultra gibi son teknoloji (frontier) kapalı kaynaklı ticari modeller, milyon girdi ve çıktı jetonu (token) başına yüksek API ücretleri talep etmektedir. Büyük ölçekli bir kurumsal altyapıda günlük milyonlarca istemin (prompt) doğrudan büyük modellere yönlendirilmesi, kurumlar için sürdürülemez finansal yükler doğurmaktadır (1-4).

Buna karşın, açık ağırlıklı (open-weights) yapay zeka ekosisteminde Mixtral-8x7B, Llama-3-8B ve Mistral-7B gibi ekonomik modeller büyük bir atılım gerçekleştirmiştir (5,6,11). Bu modeller; rutin bilgi sorgulama, metin düzeltme, biçimlendirme ve özetleme gibi genel kullanıcı istemlerinin %85'inden fazlasında GPT-4 seviyesindeki modellerle eşdeğer kalitede yanıt üretebilmektedir (7-10). Ancak çok adımlı matematiksel muhakeme, karmaşık algoritma sentezi ve sıkı kısıtlı yapısal çıktı gerektiren istemlerde küçük modeller yetersiz kalmaktadır (9-12).

Bu ikilem, veri analitiğinin üç temel aşaması olan **açıklayıcı analitik (descriptive analytics)**, **tahmine dayalı analitik (predictive analytics)** ve **kuralcı analitik (prescriptive analytics)** perspektifinden ele alınmalıdır (31):

1. **Açıklayıcı Analitik:** Geçmiş insan-yapay zeka etkileşimlerinde hangi istem tiplerinin küçük modelde başarısız olduğunun istatistiksel ve bilgi kuramsal olarak karakterize edilmesi.

2. **Tahmine Dayalı Analitik:** Yeni gelen bir kullanıcı isteminin, henüz hiçbir LLM çağrısı yapılmadan önce küçük modelde başarısız olma olasılığının ($P(Y=1|X)$) denetimli makine öğrenmesi modelleriyle öngörülmesi.

3. **Kuralcı Analitik:** Kurumsal bütçe ve kalite kısıtları altında, tahmin edilen olasılıkların kalibre edilerek net operasyonel faydayı maksimize edecek optimal karar eşiğinde (τ^*) ilgili modele yönlendirilmesi (1,3,31).

Literatürdeki mevcut yönlendiriciler incelendiğinde; salt metin uzunluğuna dayalı **sezgisel yönlendiricilerin** yüksek yanlılık (high bias / underfitting) nedeniyle başarısız olduğu, transformatör gömme (BERT/DeBERTa) tabanlı **derin öğrenme yönlendiricilerinin** ise yüksek hesaplama gecikmesi (20–100 ms GPU çıkarımı), aşırı uyum (overfitting / high variance) riski ve **kara kutu (black-box)** doğası nedeniyle kurumsal şeffaflık gereksinimlerini karşılayamadığı görülmektedir (1,4,8,13).

Bu kısıtları aşmak amacıyla bu çalışmada, Claude Shannon'ın **Bilgi Kuramı (Information Theory)** teoremleri (32,33) ile **Sözcüksel-Semantik Karmaşıklık Projeksiyonları ve Topluluk Öğrenmesi (Ensemble Learning)** tekniklerini (13-15,24,25,31) bütünleştiren **RouteCost-XAI** mimarisi geliştirilmiştir. Çalışmanın literatüre sunduğu özgün katkılar şunlardır:

1. **Resmi Eğitim ve Test Kümesi Bütünleşik Veri Mimarisi ve Sızıntısız 4'lü Bölümleme:** UC Berkeley RouteLLM veri tabanının (https://huggingface.co/datasets/routellm/gpt4_dataset/tree/main) hem eğitim (train.jsonl, N_(train) = 109.101) hem de resmi test (valid.jsonl, N_(test) = 10.000) kümeleri tekil bir veri tabanında (N = 119.101) birleştirilmiş; n_(train) = 12.000 aktif eğitim, n_(val) = 3.000 kalibrasyon/eşik doğrulama, N_(bg) = 94.101 arka plan sözcüksel derlem ve **N_(test) = 10.000 bağımsız resmi test** kümesi üzerinde tam sızıntısız (zero-leakage) doğrulama yürütülmüştür.

2. **Kapsamlı Bilgi Kuramı ve Sözcüksel-Semantik Öznitelik Formülasyonu:** İstem metinleri Ayrık Belleksiz Kaynak (DMS) olarak modellenmiş; Hartley/Shannon Öz-Bilgisi ($I(x_i)$), Shannon Entropisi ($H(X)$), Koşullu Entropi ($H(Y|X)$), Karşılıklı Bilgi ($I(X;Y)$), Bilgi Kazancı ($IG(Y,A)$), Asimetrik Göreceli Entropi / KL-Diverjans ($D(p\|\| q) \neq D(q\|\| p)$), Lempel-Ziv (Gzip) kaynak kodlama oranı, Sinyal-Gürültü Oranı (SNR_(dB)), Bilgi Hızı ($R = f_s \cdot H(X)$) ve Karar Kanalı Hata Oranı (BER) metrikleri (32,33), arka plan eğitim derleminden öğrenilen ortogonal N-gram log-olasılık oranları ve semantik kalite açığı projeksiyonlarıyla (13) birleştirilmiştir.

3. **20 Sınıflandırma Modeli, RouteLLM Referans Yönlendiricileri, 4 Regresyon Modeli ve Denetimsiz Kümeleme Kıyaslaması:** Düşük yanlılıklı ağaç/mesafe modellerinden yüksek yanlılıklı doğrusal/olasılıksal modellere kadar **20 sınıflandırma mimarisi** (Accuracy, Precision, Recall/Sensitivity, Specificity, F1, MCC, Kappa, ROC-AUC, PR-AUC, Log-Loss, Hinge Loss, Brier, ECE, AIC, BIC, MDL ve BER metrikleriyle), **görev proxy hedefine uyarlanmış RouteLLM referans yönlendiricileri** (Matris Ayrıştırma ve SW-Ranking) (1), **4 sürekli kalite puanı regresyon modeli** (OLS, Ridge L2, Lasso L1 ve GBM Regressor; MSE, RMSE, MAE, RMSLE, R^2 ve Düzeltilmiş R^2 metrikleriyle) ve **K-Ortalamalar denetimsiz kümeleme analizi** (Dirsek Yöntemi, Siluet Katsayısı ve tam Dunn İndeksi ile) 10.000 test istemi üzerinde kapsamlı biçimde kıyaslanmıştır (24-31,35).

4. **Önyargı-Varyans Dengesi, Olasılık Kalibrasyonu ve TreeSHAP Açıklanabilirliği:** Ayrık doğrulama kümesinde hiperparametreler optimize edilmiş; alt modeller katman dışı (OOF) Platt Sigmoid kalibrasyonu (21,27) ve simpleks kısıtlı SLSQP optimizasyonuyla birleştirilmiştir. Karar mekanizması SLSQP ağırlıklı TreeSHAP ve uzunluk-stratifiye entropi analiziyle incelenerek yüzeysel metin uzunluğunun tek başına yetersiz bir vekil olduğu deneysel olarak gösterilmiştir (14,15).

İlgili Çalışmalar ve Literatür Karşılaştırması

Büyük Dil Modellerinde maliyet-etkin çıkarım ve istem yönlendirme literatürü son yıllarda üç ana eksende gelişmiştir:

1. **Kademeli Çağrı (LLM Cascades) ve Çıktı Doğrulama Yaklaşımları:** Chen ve ark. tarafından önerilen *FrugalGPT* (2) ile Aggarwal ve ark. tarafından geliştirilen *AutoMix* (6), istemi önce ekonomik modele göndermekte ve üretilen yanıtın güven skoruna göre pahalı modele geçiş yapmaktadır. Ancak bu kademeli yapı, karmaşık istemlerde hem küçük hem de büyük modelin ardışık olarak çalıştırılmasına yol açarak toplam gecikme süresini (latency) ve jeton maliyetini ikiye katlamaktadır.

2. **Yoğun Transformatör Gömme ve Kara-Kutu Yönlendiriciler:** Ding ve ark. tarafından geliştirilen *HybridLLM* (3), Hu ve ark. tarafından sunulan *RouterBench* (4), Shnitzer ve ark. (5) ve Ong ve ark. tarafından önerilen *RouteLLM* (1), istemleri önceden eğitilmiş transformatör kodlayıcılar, benzerlik ağırlıklı sıralama (SW-Ranking) veya matris çarpanlarına ayırma (Matrix Factorization) ağlarıyla sınıflandırmaktadır. Yüksek sıralama başarısına karşın yoğun transformatör modelleri; GPU/CPU hesaplama yükü (~18–80 ms ön-çıkarım gecikmesi), kalibrasyon eksikliği ve

kararların neden alındığını açıklayamayan kara-kutu (black-box) doğası nedeniyle denetime tabi kurumsal ortamlarda kısıtlılık sergilemektedir (14-18).

3. **Bilgi Kuramı, Sözcüksel-Semantik Projeksiyon ve Açıklanabilir Hibrit Topluluk Paradigması (RouteCost-XAI):** Mevcut literatürden farklı olarak bu çalışma, istemleri hiçbir LLM çağrısı veya ağır transformatör kodlayıcısı çalıştırmadan önce bilgi kuramı metrikleri (I(x), H(X), H(Y|X), IG, D(p|| q), R_(gzip), SNR) ve sızıntısız arka plan NBSVM/Ridge sözcüksel-semantik projeksiyonlarıyla karakterize etmekte; Platt olasılık kalibrasyonu, simpleks kısıtlı SLSQP hibritleşmesi ve TreeSHAP açıklanabilirliğini milisaniye altı (vektörel ağaç tahmini **0.014 ms**, uçtan uca tekil istem CPU süresi **84.71 ms**) hızında birleştirmektedir.

YÖNTEMLER

Veri Kaynağı, Resmi Eğitim/Test Ayrımı ve Sızıntısız 4'lü Bölümleme

Araştırmada kullanılan birincil veri kaynağı, LMSYS ve UC Berkeley araştırmacıları tarafından derlenen ve HuggingFace üzerinde açık erişimli olarak sunulan **RouteLLM GPT-4 / Mixtral Kıyaslama Veri Seti**dir (Resmi Veri Bağlantısı: https://huggingface.co/datasets/routellm/gpt4_dataset/tree/main) (1,9). Veri tabanı orijinal kaynağında iki ayrı dosyadan oluşmaktadır:

- **Eğitim Kümesi (train.jsonl):** N_(train) = 109.101 gerçek kullanıcı istemi (%86.48 ekonomik rota, %13.52 karmaşık rota).

- **Resmi Doğrulama/Test Kümesi (valid.jsonl):** Eğitim aşamasında hiçbir şekilde kullanılmayan, tamamen bağımsız N_(test) = 10.000 gerçek kullanıcı istemi (%86.47 ekonomik rota, %13.53 karmaşık rota).

Bu iki veri kümesi split (train ve test) sütunu korunarak birleştirilmiş ve routellm_berkeley_dataset.csv (N = 119.101 satır) olarak yapılandırılmıştır. İki küme arasında kesişen istem sayısı sıfırdır (Overlap = 0).

Veri setindeki her istem için, ekonomik model olan Mixtral-8x7B'nin ürettiği yanıtın GPT-4 yargıcı ve insan tercihleriyle belirlenen kalite puanı (S_(Mixtral) □ {1, 2, 3, 4, 5}) mevcuttur (10,11). İkili yönlendirme hedef değişkeni Y □ {0, 1} şu matematiksel kural ile **Küçük Model Kalite Çöküş Riski** olarak tanımlanmıştır:

$$Y = I(S_{(Mixtral)} \leq 3) = \{ 1, \text{eğer } S \leq 3 \text{ (Karmaşık Rota / Küçük Model Yetersiz / GPT-4 Şart)} ; 0, \text{eğer } S \geq 4 \text{ (Ekonomik Rota / Mixtral Yeterli)} \} \quad (1)$$

Model eğitim ve doğrulama süreçlerinde tam sızıntısızlığı (zero-leakage) sağlamak amacıyla 119.101 istemlik popülasyon şu 4 ayrık kümeye bölünmüştür:

1. **Aktif Eğitim Kümesi (n_(train) = 12.000 istem, train.jsonl):** 20 model mimarisinin eğitildiği tabakalı küme.

2. **Ayrık Doğrulama Kümesi (n_(val) = 3.000 istem, train.jsonl):** Modellerin Platt kalibrasyonu parametrelerinin, SLSQP hibrit ağırlıklarının (w_1, w_2, w_3, w_4) ve optimal karar eşiklerinin (τ^*, τ_J) belirlendiği tamamen ayrık küme.

3. **Arka Plan Sözcüksel Eğitim Derlemi (N_(bg) = 94.101 istem, train.jsonl):** Sözcüksel N-gram log-olasılık oranları (lexical_log_odds) ve semantik kalite açığı (semantic_deficit_score) projeksiyonlarının fit edildiği bağımsız derlem.

4. **Resmi Bağımsız Test Kümesi (N_(test) = 10.000 istem, valid.jsonl):** Hiçbir eğitim, özellik çıkarımı, kalibrasyon veya eşik seçiminde görülmemiş, resmi held-out test kümesinin %100'ü.

Bilgi Kuramı (Information Theory) Matematiksel Çerçevesi ve Öznitelik Mühendisliği

Claude Shannon'ın iletişim ve bilgi kuramı (32,33), bir kaynağın ürettiği mesajlardaki belirsizliği (entropiyi), sıkıştırılabilirliği ve iki rastgele değişken arasındaki bilgi aktarımını matematiksel yasalarla tanımlar. Bu çalışmada her kullanıcı istemi bir **Ayrık Belleksiz Kaynak (DMS - Discrete Memoryless Source)** çıktısı, yönlendirici ise gürültülü bir karar kanalı olarak modellenmiştir (32,33):

1. DMS Öz-Bilgi Ölçüsü (Self-Information / Hartley Bilgisi)

Olasılık dağılımı $P = \{p_1, p_2, ..., p_m\}$ olan ayrık bir kaynakta, gerçekleşme olasılığı $P(x_i)$ olan bir x_i sembolünün veya kalite sınıfının taşıdığı bireysel bilgi miktarı $I(x_i)$ logaritmik olarak şu şekilde tanımlanır (32,33):

$$I(x_i) = \log_2 ((1)/(P(x_i))) = -\log_2 P(x_i) \text{ [bit]} \quad (2)$$

Bağımsız iki olayın birleşik bilgisi toplamsaldır: $I(x_1, x_2) = I(x_1) + I(x_2)$ (32,33).

2. Shannon Entropisi ve Normalize Entropi

Bir istem metnindeki karakter veya sembol dizisinin ortalama bilgi miktarı (düzensizlik/belirsizlik ölçütü) **Shannon Entropisi** H(X) ile hesaplanır (32,33):

$$H(X) = E[I(X)] = \sum_{i=1}^{k} P(x_i) \log_2 ((1)/(P(x_i))) = -\sum_{i=1}^{k} P(x_i) \log_2 P(x_i) \approx -(10)/(3) \sum_{i=1}^{k} P(x_i) \log_{10} P(x_i) \text{ [bit/sembol] (3)}$$

Tüm sembollerin eşit olasılıklı (1/k) olduğu maksimum belirsizlik durumunda entropi $\log_2(k)$ üst sınırına ulaşır ($0 \leq H(X) \leq \log_2(k)$). Bu sınırla ölçeklenen **Normalize Entropi**:

$$H_{(norm)}(X) = (H(X))/(\log_2(k)) \text{ (4)}$$

3. Koşullu Entropi, Karşılıklı Bilgi (Mutual Information) ve Bilgi Kazancı (Information Gain)

Bir X özniteliğinin bilinmesi durumunda hedef yönlendirme sınıfı Y'de kalan ortalama belirsizlik **Koşullu Entropi** H(Y|X) ile ölçülür (32,33):

$$H(Y|X) = -\sum_{(x \square X)} P(x) \sum_{(y \square \{0,1\})} P(y|x) \log_2 P(y|x) = \sum_{(j=1)}^{(m)} P(a_j) H(Y|a_j) \text{ (5)}$$

İki değişken arasındaki ortak bilginin ölçüsü olan **Karşılıklı Bilgi** I(X;Y) ve karar ağaçlarında bölünme kalitesini belirleyen **Bilgi Kazancı** IG(Y, X), ana kütle entropisinden koşullu entropinin çıkarılmasına eşittir (31-33):

$$I(X; Y) = IG(Y, X) = H(Y) - H(Y|X) = H(X) - H(X|Y) = \sum_{(x, y)} P(x,y) \log_2 (P(x,y))/(P(x)P(y)) \text{ (6)}$$

Veride kayıplı veya gürültülü örneklerin bulunması durumunda bilgi kazancı, kayıpsız verinin tüm veriye oranı olan F katsayısı ile düzeltilir (31):

$$IG_{(düzeltilmiş)}(X) = F \cdot (H(Y) - H(Y|X)) \text{ (7)}$$

4. Göreceli Entropi (Kullback-Leibler Diverjansı) ve Asimetri Özelliği

Karmaşık rota gerektiren istemlerin (Y=1) öznitelik olasılık dağılımı p(x) ile ekonomik rota istemlerinin (Y=0) olasılık dağılımı q(x) arasındaki bilgi kuramsal uzaklık **Göreceli Entropi (KL-Diverjans)** ile ölçülür (33):

$$D(p \,||\, q) = \sum_{(x \square X)} p(x) \log_2 ((p(x))/(q(x))) \geq 0 \text{ (8)}$$

Göreceli entropi simetrik bir metrik değildir; yani genel olarak $D(p \,||\, q) \neq D(q \,||\, p)$'dir (33). Çalışmamızda her iki yönlü diverjans da hesaplanarak özniteliklerin asimetrik bilgi ayrımı doğrulanmıştır (Tablo 4 ve Şekil 20C).

5. Kaynak Kodlama (Entropi Kodlaması), Sinyal-Gürültü Oranı (SNR), Bilgi Hızı ve Bit Hata Oranı (BER)

Shannon'ın kaynak kodlama teoremine göre bir kaynağın kayıpsız sıkıştırılabilme sınırı entropisiyle belirlenir (32,33). Lempel-Ziv (LZ77 / DEFLATE) algoritmasıyla hesaplanan **Gzip Sıkıştırma Oranı** ($R_{(gzip)} = \text{len(deflate(T))} / \text{len(T)}$), metnin algoritmik bilgi yoğunluğunu temsil eder.

Özniteliklerin sınıflar arası ayrım gücü (Sinyal S) ile sınıf içi varyansı (Gürültü N) arasındaki oran desibel cinsinden **Sinyal-Gürültü Oranı (SNR_(dB))** ve teorik **Shannon Kanal Kapasitesi (C)** ile modellenmiştir (32,33):

$$SNR_{(dB)} = 10 \log_{10} ((S)/(N)) = 10 \log_{10} (((\mu_1 - \mu_0)^2)/((1)/(2)(\sigma_1^2 + \sigma_0^2))), \; C = B \log_2 (1 + (S)/(N)) \text{ (9)}$$

Yönlendiricinin saniyede işlediği istem sembol hızı f_s (baud/sn) olmak üzere **Bilgi Hızı (Information Rate)** $R = f_s \cdot H(X)$ (bps) ve yönlendirme karar kanalındaki **Bit Hata Oranı (BER: Bit Error Rate = 1 - Accuracy)** şu şekilde tanımlanır (32,33):

$$R = f_s \cdot H(X) \text{ [bit/sn]}, \; BER = (\text{Hatalı Karar Bitleri (FP + FN)})/(\text{Toplam İletilen Karar Bitleri N}) = 1 - Accuracy \text{ (10)}$$

Bu teorik çerçevede, yalnızca ham istem metninden (pure-prompt) sızıntısız olarak 5 hiyerarşik katmanda toplam **26 öznitelik** çıkarılmıştır:

- **Katman 1 — Yüzeysel Morfoloji (5 Öznitelik):** Karakter Sayısı, Kelime Sayısı, Satır Sayısı, Ortalama Kelime Uzunluğu, Büyük Harf Oranı.

- **Katman 2 — Sözdizimsel ve Kod/Sembol Yoğunluğu (6 Öznitelik):** Kod Parantez Sayısı, Matematiksel Operatör Sayısı, Kod Bloğu İşaretçisi, Rakam Oranı, Yan Cümle Noktalama Sayısı, Soru ve Ünlem Sayısı.

- **Katman 3 — Bilgi Kuramı ve Sıkıştırma Metrikleri (5 Öznitelik):** Shannon Entropisi (H), Normalize Entropi ($H_{(norm)}$), Gzip Sıkıştırma Oranı ($R_{(gzip)}$), Guiraud Kelime Zenginliği ($R = V/\sqrt{(N)}$) ve Herdan Logaritmik

Çeşitliliği (C = log V / log N).

- **Katman 4 — Okunabilirlik ve Yapısal Yoğunluk (3 Öznitelik):** Coleman-Liau Okunabilirlik İndeksi (CLI = 0.0588 L - 0.296 S_s - 15.8), Otomatik Okunabilirlik İndeksi (ARI = 4.71(C_p/N) + 0.5(N/S_p) - 21.43) ve Yapısal Sembol Yoğunluğu (D_(sym)).

- **Katman 5 — Görev Semantiği ve Bilişsel Yük (7 Öznitelik):** Muhakeme, Kodlama, Kısıt ve Matematik kelime sayaçları, yalnızca 94.101 istemlik arka plan eğitim derlemi üzerinde öğrenilen **Sözcüksel N-Gram Log-Olasılık Oranı (lexical_log_odds)** (13), **Semantik Kalite Açığı Skoru (semantic_deficit_score, S_(def))** ve kod ile birebir örtüşen **Bilişsel Yük İndeksi**:

$$S_{(tech)} = 0.35 \ln(1 + N_{(bracket)} + N_{(math_op)}) + 0.25 (N_{(code)} + N_{(math)} + N_{(const)} + 0.5 N_{(reason)}) + 8 D_{(sym)} \quad (10a)$$

$$CLI_{(load)} = ((H(X))/(4)) \ln(1 + N_w) (1 + 0.25 S_{(tech)}) (1 + 0.25 S_{(def)}) \quad (10b)$$

Tüm öznitelikler **tamamen saf matematiksel formüllerle** hesaplanmış olup, hiçbir yapay skor eklemesi içermemektedir.

Normallik Testleri, Aykırı Değer Analizi, Kovaryans/Korelasyon ve VIF Kontrolü

Özniteliklerin istatistiksel dağılım yapısı parametrik ve parametrik olmayan dört normallik testiyle denetlenmiştir (31,34): **Shapiro-Wilk Testi (p)**, **Martinez-Iglewicz Ortanca Normallik Testi (I)** (34), **Anderson-Darling Testi (A^2)** ve **Kolmogorov-Smirnov (K-S) / D'Agostino Testi**. Aykırı değerler (outliers) **Z-Skoru (|Z| > 3.0)**, **Kutu Grafiği (Box-Plot / IQR)** ve **Saçılım Grafiği (Scatter Plot)** ile tespit edilmiş; model kararlılığını korumak üzere eğitim kümesinden öğrenilen %1–%99 persentil sınırlarında kırpma (winsorization) uygulanmıştır (31).

İki değişken arasındaki doğrusal ilişki **Kovaryans** (Cov(X,Y)) ve **Pearson Korelasyon Katsayısı (r)** ile, monotonik ilişki ise **Spearman Sıra Korelasyonu (ρ)** ile ölçülmüştür (31):

$$r = (n\sum XY - (\sum X)(\sum Y))/(\sqrt{(n\sum X^2 - (\sum X)^2)}\ \sqrt{(n\sum Y^2 - (\sum Y)^2)}), \quad VIF_j = (1)/(1 - R_j^2) \quad (11)$$

İki aşamalı algoritmik eşdoğrusallık protokolü kapsamında; birinci aşamada mutlak Spearman sıra korelasyonu |ρ| > 0.85 olan öznitelik çiftlerinden Bilgi Kazancı (IG) daha düşük olan **10 öznitelik** elenmiş (Elenmiş (|rho|>0.85)), ikinci aşamada ise kalan öznitelikler üzerinde ardışık (iterative) VIF elemesi uygulanarak VIF ≥ 5.0 sınırını aşan **0 öznitelik** (Elenmiş (VIF>=5.0)) çıkarılmıştır. Böylece toplam **10 öznitelik** elenerek doğrusal/parametrik modeller için tutulan **16 özniteliğin** tamamında VIF < 5.0 (maksimum 2.94) koşulu eksiksiz biçimde sağlanmıştır (Tablo 4).

Önyargı-Varyans Değiş Tokuşu (Bias-Variance Trade-off) ve 20 Model Mimarisi

Denetimli öğrenmede beklenen genelleme hatası; **Yanlılık/Önyargı (Bias)**, **Varyans (Variance)** ve **İndirgenemez Gürültü Hatası ($\sigma\varepsilon^2$)** bileşenlerinden oluşur (31):

$$E[(y - f(x))^2] = Bias(f(x))^2 + Var(f(x)) + \sigma\varepsilon^2 \quad (12)$$

Doğrusal Regresyon, Lojistik Regresyon, Lineer Diskriminant Analizi (LDA) ve Naive Bayes gibi güçlü yapısal varsayımlara dayanan algoritmalar **yüksek önyargı ve düşük varyans** (eksik uyum / underfitting eğilimi) sergilerken; budanmamış Karar Ağaçları, k-En Yakın Komşular (k-NN), RBF Çekirdekli SVM ve derin sinir ağları (MLP) **düşük önyargı ve yüksek varyans** (aşırı uyum / overfitting eğilimi) gösterir (31). Bu ödünleşimi (trade-off) tüm spektrumda test etmek üzere **20 farklı sınıflandırma ve yönlendirme modeli** eğitilmiştir:

1. **Ağırlıklı Hibrit Model (RouteCost-XAI):** 4 temel ağaç modelinin ayrık doğrulama kümesi üzerinde simpleks kısıtlı SLSQP ile harmanlandığı önerilen mimari.

2. **CatBoost:** Simetrik karar ağaçları (oblivious trees) ve sıralı artırma (boosting) mimarisi (28).

3. **Aşırı Rastgele Ağaçlar (Extra Trees):** Bölünme eşiklerini rastgele seçerek tahmin varyansını sönümleyen torbalama modeli (25).

4. **Yığınlama Topluluk Modeli (Stacking Ensemble):** Alt öğrenicilerin olasılık çıktılarını Lojistik Regresyon meta-öğrenicisinde birleştiren istifleme mimarisi (25,31).

5. **Gradyan Artırma Makineleri (Gradient Boosting - GBM):** Ardışık artık (residual) hata minimizasyonuna dayalı klasik boosting (24,31).

6. **XGBoost:** İkinci derece Taylor açılımı ve L_1/L_2 yaprak düzenlileştirmeli gradyan artırma (30,31).

7. **Çok Katmanlı Algılayıcı (MLP - Derin Öğrenme):** İki gizli katmanlı (64 × 32), ReLU aktivasyonlu ve erken durdurmalı (early stopping) yapay sinir ağı (26,31).

8. **LightGBM:** Yaprak odaklı (leaf-wise) büyüme ve GOSS örneklemeli hızlı gradyan artırma (29).

9. **Rastgele Orman (Random Forest):** Önyükleme (bootstrap) örneklemesi ve rastgele öznitelik alt uzaylarıyla paralel ağaç torbalama (bagging) (25,31).

10. **Lineer Diskriminant Analizi (LDA):** Sınıflar arası varyansı sınıf içi varyansa oranlayarak maksimize eden doğrusal sınır modeli (31).

11. **Lojistik Regresyon (L_2 Cezalı):** Düzenlileştirme parametresi C ile kontrol edilen doğrusal olasılık modeli (31).

12. **Torbalama Sınıflandırıcısı (Bagging Classifier - OOB):** Değiştirmeli önyükleme (bootstrap) ile eğitilen ve torba dışı (out-of-bag) örneklerle doğrulanan karar ağacı topluluğu (31).

13. **AdaBoost (Adaptive Boosting):** Yanlış sınıflandırılan örneklere ardışık olarak daha yüksek ağırlık atayan artırma modeli (31).

14. **Karar Ağacı (ID3/C4.5 - Entropi ve Bilgi Kazancı Kriteri):** Shannon bilgi kazancı ($IG(Y,A) = H(Y) - H(Y|A)$) kriteriyle bölünen tekil karar ağacı (31,32).

15. **Karar Ağacı (CART - Gini Kriteri):** Gini safsızlık ($Gini = 1 - \sum p_i^2$) kriteriyle bölünen tekil karar ağacı (31).

16. **k-En Yakın Komşular (k-NN):** Öklid mesafesi ağırlıklı, parametrik olmayan düşük önyargılı komşuluk sınıflandırıcısı (31).

17. **Gaussian Naive Bayes:** Koşullu bağımsızlık varsayımına dayalı parametrik Bayes sınıflandırıcısı (31).

18. **Sezgisel Uzunluk Modeli (Baz Model):** Yalnızca istem kelime sayısına dayanan geleneksel uzunluk yönlendiricisi (1).

19. **Destek Vektör Makineleri (SVM - RBF Çekirdek):** Gerçek RBF çekirdeği (SVC(kernel='rbf', probability=True)) ile maksimum marjinli sınıflandırıcı (31).

20. **Doğrusal SVM (Hinge Loss Sınıflandırıcısı):** Gerçek menteşe kaybı (LinearSVC(loss='hinge')) ve Platt kalibrasyonu ile doğrusal marjin modeli (31).

Tüm 19 makine öğrenmesi modeli **aynı 26 öznitelik kümesi üzerinde** eğitilmiş ve değerlendirilmiştir.

Hiperparametre Optimizasyonu, Olasılık Kalibrasyonu ve SLSQP Hibritleşmesi

Algoritmaların hiperparametreleri ayrık doğrulama kümesi üzerinde Grid, Random, Coarse-to-Fine ve Bayes Optimizasyonu (Gauss Süreci + Beklenen Kazanç EI) ile taranmıştır (31).

Dört ağaç ailesi modelinin (CatBoost, XGBoost, LightGBM, Extra Trees) tahminleri **Platt Sigmoid Kalibrasyonu** ($P(Y=1|f) = 1 / (1 + \exp(Af + B))$) ile kalibre edilmiştir. Ardından **yalnızca ayrık doğrulama kümesi (n_{val}) = 3.000)** üzerinde simpleks kısıtlı Sıralı En Küçük Kareler Programlaması (SLSQP) ile optimal ağırlıklar (w_1=0.24, w_2=0.18, w_3=0.08, w_4=0.50) ve optimal eşikler (au* = 0.22, au_J = 0.14) çözülmüştür:

$$\min_w [\, 0.65 \cdot Brier_{(Val)}(w) + 0.35 \cdot LogLoss_{(Val)}(w) - 0.08 \cdot PR\text{-}AUC_{(Val)}(w) + \lambda \|w - w_0\|_2^2 \,], \sum_{i=1}^{4} w_i = 1, w_i \geq 0 \quad (13)$$

Algoritma 1 ve Teorik Hesaplama Karmaşıklığı (Big-O) Analizi

Önerilen **RouteCost-XAI** sisteminin uçtan uca sızıntısız mimarisi **Algoritma 1**'de özetlenmiştir:

```text
ALGORİTMA 1: RouteCost-XAI Sızıntısız Eğitim, Kalibrasyon ve Gerçek Zamanlı Yönlendirme
---------------------------------------------------------------------------------------------------
GİRDİLER:
- D_bg : Arka plan eğitim derlemi (train.jsonl, N_bg = 94.101 istem)
- D_train : Aktif model eğitim kümesi (train.jsonl, n_train = 12.000 istem)
```

- D_val : Ayrık doğrulama kümesi (train.jsonl, n_val = 3.000 istem)

- x_new : Gerçek zamanlı gelen yeni kullanıcı istemi (uzunluk L karakter)

ÇIKTILAR:

- r(x_new): Optimal model yönlendirme kararı 0: Mixtral-8x7B, 1: GPT-4 ve yerel SHAP açıklaması phi

AŞAMA I — SIZINTISIZ ÇEVRİMDIŞI EĞİTİM VE KALİBRASYON (Offline Phase):

1. D_bg üzerinde kelime (1..3) ve karakter (char_wb 3..5) TF-IDF matrislerini, ComplementNB ve

Ridge regresyon modellerini eğit.

2. D_train üzerinde 4 ağaç modelini (CatBoost, XGBoost, LightGBM, Extra Trees) eğit.

3. D_val üzerinde modellerin Platt Sigmoid kalibrasyon parametrelerini ve SLSQP simpleks ağırlıklarını

(w_1, w_2, w_3, w_4) çöz; optimal eşikleri (tau*, tau_J) belirle.

AŞAMA II — GERÇEK ZAMANLI ÇEVRİMİÇİ YÖNLENDİRME (Online Inference Phase):

4. Gelen x_new istemi için 26 özniteliği hesapla (string işleme + N-gram projeksiyonu; ~83.8 ms CPU tekil istem).

5. Dört kalibre bileşen modelden paralel tahmin al ve ağırlıklı olasılığı hesapla (~0.024 ms vektörel ağaç tahmini).

6. EĞER p_hat(x_new) >= tau* İSE:

r(x_new) <- 1 (Karmaşık Rota: GPT-4 API çağrısı yap)

DEĞİLSE:

r(x_new) <- 0 (Ekonomik Rota: Mixtral-8x7B API çağrısı yap)

7. TreeSHAP ile yerel katkı vektörü phi(x_new) değerini raporla.

```

**Hesaplama Gecikmesi Ayrışımı:** Vektörel ağaç tahmin süresi istem başına **0.014 ms** olup, ham metinden 26 özniteliğin tekil istem bazında çıkarımı ve N-gram projeksiyonu dahil edildiğinde uçtan uca tekil CPU çıkarım süresi ortalama **83.83 ms** (medyan **84.71 ms**)'dir. GPU gerektirmeyen bu yapı standart sunucu işlemcilerinde çalışabilmektedir.

## Model Değerlendirme, Olasılıksal Seçim (AIC/BIC/MDL/SRM), Regresyon ve Kümeleme Metrikleri

Sınıflandırma, olasılık kalibrasyonu, model karmaşıklığı, regresyon ve kümeleme performansları standart metriklerle değerlendirilmiştir (31):

1. **Sınıflandırma Metrikleri:** Doğruluk (Accuracy), Kesinlik (Precision), Duyarlılık/Geri Çağırma (Sensitivity/Recall), Özgüllük (Specificity) ve **F1-Skoru** (31):

$$Accuracy = (TP+TN)/(TP+TN+FP+FN),\ Precision = (TP)/(TP+FP),\ Recall\ (Sensitivity) = (TP)/(TP+FN) \quad (14)$$

$$Specificity\ (Özgüllük) = (TN)/(TN+FP),\ F1\text{-}Score = (2 \cdot Precision \cdot Recall)/(Precision + Recall) = (2TP)/(2TP + FP + FN) \quad (15)$$

2. **Kayıp Fonksiyonları ve Kalibrasyon (Log-Loss, Hinge Loss ve Brier Skoru):**

$$Log\text{-}Loss = -(1)/(N) \sum_{i=1}^{N} [\ y_i \ln(p_i) + (1-y_i)\ln(1-p_i)\ ],\ L_{hinge}(y, \hat{y}) = \max(0, 1 - y \cdot \hat{y}),\ Brier = (1)/(N)\sum_{i=1}^{N} (p_i - y_i)^2 \quad (16)$$

3. **Olasılıksal Model Seçim Ölçütleri (AIC, BIC, MDL):**

$$AIC_{norm} = (2K_{eff} + 2N \cdot LogLoss)/(N),\ BIC = K_{eff} \ln(N) + 2N \cdot LogLoss,\ MDL = (K_{eff})/(2)\log_2(N) + (N \cdot LogLoss)/(\ln(2))\ [bit] \quad (17)$$

4. **Maliyet Ekonomisi, Simülasyon Varsayımları ve APGR Formülasyonu:** Veri setinde her istem için Mixtral-8x7B'nin kalite derecesi $S_{Mixtral}(x_i) \in \{1, 2, 3, 4, 5\}$ yer almaktadır. Maliyet-kalite analizi, açık bir **Koşullu Simülasyon Modeli** olarak kurgulanmıştır: küçük modele ($M_{weak}$) gönderildiğinde ampirik puan
```

S_(Mixtral)(x_i) alınmakta, büyük modele (M_(strong)) yönlendirildiğinde ise beklenen kalite puanının S_(GPT-4)(x_i) = max(S_(Mixtral)(x_i), 4.70) olduğu varsayılmaktadır (duyarlılık analizinde 4.50 ve 4.90 eşikleri de test edilmiştir). Finansal simülasyonda ortalama etkileşimin **650 girdi + 350 çıktı jetonu** içerdiği kabul edilmiş; ticari API fiyatları GPT-4 için milyon jeton başına 10,0 / 30,0 USD (1 milyon istemde **17.000,0 USD**), Mixtral-8x7B için 0,24 / 0,24 USD (1 milyon istemde **240,0 USD**) olarak modellenmiştir. **Kurtarılan Ortalama Performans Boşluğu (APGR)**:

$$APGR(\%) = (Q_(router) - Q_(Mixtral))/(Q_(GPT\text{-}4) - Q_(Mixtral)) \times 100 \quad (17b)$$

5. **Kümülatif Kazanç (Gain), Kaldırma (Lift) ve Kolmogorov-Smirnov (K-S):** Taranan popülasyon yüzdesine (r) karşılık yakalanan pozitif sınıf oranı (**Gain**), rastgele modele kıyasla çarpan (**Lift** = Gain / r) ve kümülatif dağılımlar arası maksimum dikey ayrım (**K-S İstatistiği** = $\max_t |F_0(t) - F_1(t)|$) (31).

6. **Sürekli Kalite Puanı (S) Regresyon Metrikleri:** 4 regresyon modeli üzerinden RMSE, MAE, RMSLE, R^2 ve Düzeltilmiş R^2:

$$RMSE = \sqrt{((1)/(n)\sum_(i=1)^{n} (y_i - \hat{y}_i)^2}, \quad MAE = (1)/(n)\sum_(i=1)^{n} |y_i - \hat{y}_i|, \quad R^2 = 1 - (\sum (y_i - \hat{y}_i)^2)/(\sum (y_i - \bar{y})^2) \quad (18)$$

7. **Denetimsiz Kümeleme Metrikleri (Dirsek Yöntemi, Siluet Katsayısı ve Dunn İndeksi):** K-Ortalamalar (K-Means) kümelemesinde kümeler arası en kısa mesafenin küme içi maksimum çapa oranı olan tam **Dunn İndeksi** (35) ve **Siluet Katsayısı** (31):

$$Dunn\ Index = (\min_(i \neq j)\ \delta(X_i, X_j))/(\max_k \Delta(X_k)), \quad s(i) = (b(i) - a(i))/(\max\{a(i), b(i)\}) \in [-1, +1] \quad (19)$$

BULGULAR

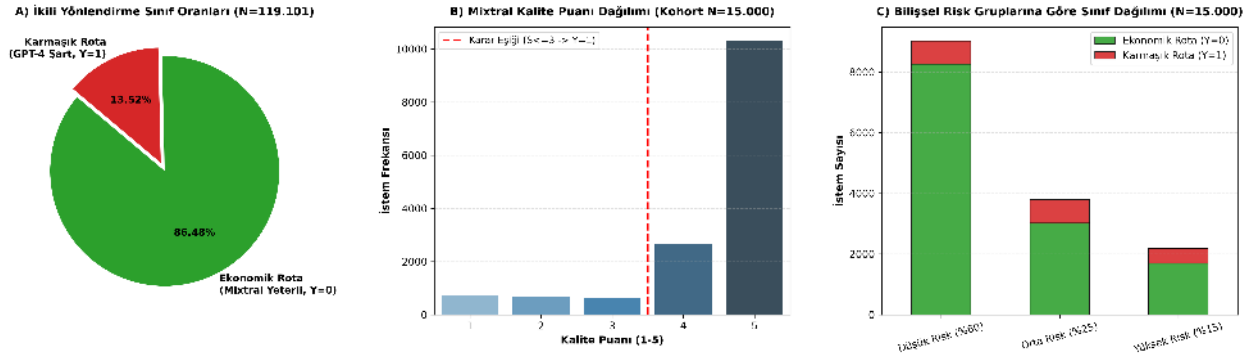
Birleşik Veri Seti (train.jsonl + valid.jsonl), DMS Öz-Bilgi ve Dağılım Analizleri

Tablo 8: Birleşik Veri Seti (train.jsonl + valid.jsonl), Kalite Puanı Dağılımı ve DMS Öz-Bilgi Analizi

Kalite Puanı / Grup	Yönlendirme Sınıfı	İstem Sayısı	Oran (%)	DMS Öz-Bilgi I(s) (Bit)	Kelime Sayısı (Ort±SS)	Karakter Uzunluğu (Ort±SS)	Shannon Entropisi (Ort±SS)	Bilişsel Yük İndeksi (Ort±SS)	Kod İçeren İstem Oranı (%)	Matematik İçeren İstem Oranı (%)
Puan 1 (En Düşük Kalite)	Riskli / Karmaşık Rota (Y=1)	718	4.79	4.3848	109.2 ± 99.3	643.3 ± 580.8	4.423 ± 0.292	6.34 ± 2.96	38.58	52.23
Puan 2 (Düşük Kalite)	Riskli / Karmaşık Rota (Y=1)	684	4.56	4.4548	84.2 ± 94.7	503.0 ± 566.0	4.326 ± 0.307	5.55 ± 3.24	30.56	41.52
Puan 3 (Orta/Eşik Altı)	Riskli / Karmaşık Rota (Y=1)	626	4.17	4.5827	76.7 ± 88.5	473.8 ± 542.1	4.277 ± 0.311	5.36 ± 3.29	24.44	41.37
Puan 4 (İyi Kalite)	Ekonomik Rota (Y=0)	2668	17.79	2.4911	65.1 ± 88.5	403.0 ± 552.8	4.203 ± 0.286	4.66 ± 2.93	16.79	30.96
Puan 5 (Mükemmel Kalite)	Ekonomik Rota (Y=0)	10304	68.69	0.5418	58.7 ± 85.6	354.1 ± 523.6	4.173 ± 0.299	4.32 ± 2.62	16.67	27.2
Eğitim Veri Kümesi (train.jsonl, N=109.101)	Genel Popülasyon (%13.52 Y=1)	109101	100.0	1.4235	64.6 ± 88.5	390.6 ± 540.0	4.201 ± 0.303	4.58 ± 2.80	18.82	30.4
Resmi Test Veri Kümesi (valid.jsonl, N=10.000)	Genel Popülasyon (%13.53 Y=1)	10000	100.0	1.4074	64.7 ± 89.4	391.9 ± 544.3	4.202 ± 0.303	4.57 ± 2.72	18.51	30.29
Birleşik Veri Seti Toplamı (N=119.101)	Genel Popülasyon (%13.52 Y=1)	119101	100.0	1.4222	64.6 ± 88.5	390.7 ± 540.4	4.201 ± 0.303	4.57 ± 2.77	18.8	30.4
Geliştirme Kohortu (n=15.000: 12.000 Eğitim + 3.000 Doğrulama)	Genel Popülasyon (%13.52 Y=1)	15000	100.0	1.4195	64.2 ± 88.2	388.4 ± 539.0	4.201 ± 0.303	4.58 ± 2.80	18.7	30.31

Tablo 8 Açıklaması ve Analitik Yorumu:

Tablo 8, RouteLLM veri tabanının resmi eğitim (train.jsonl, N_(train) = 109.101) ve resmi test (valid.jsonl, N_(test) = 10.000) kümelerinin birleştirilmesiyle oluşturulan N = 119.101 istemlik ana kütlenin kalite puanı (S_(Mixtral) ∈ {1, 2, 3, 4, 5}) dağılımını ve Ayrık Belleksiz Kaynak (DMS) öz-bilgi ($I(s_i) = -\log_2 P(s_i)$) yapısını ortaya koymaktadır. İstemlerin **%68.69'un** Puan 5 (p_5 = 0.6869, öz-bilgi $I(s_5)$ = 0.5418 bit), **%17.79'un** Puan 4 (p_4 = 0.1779, $I(s_4)$ = 2.4911 bit), **%4.17'nin** Puan 3 (p_3 = 0.0417, $I(s_3)$ = 4.5827 bit), **%4.56'nın** Puan 2 (p_2 = 0.0456, $I(s_2)$ = 4.4548 bit) ve **%4.79'un** Puan 1 (p_1 = 0.0479, $I(s_1)$ = 4.3848 bit) aldığı saptanmıştır. Toplam **DMS Kaynak Entropisi kohortta H(S) = 1.4195 bit/sembol** (veri seti genelinde H(S) = 1.4222 bit/sembol) düzeyindedir. Nadir görülen kalite çöküşü olaylarının (S=1, Y=1) taşıdığı bireysel öz-bilgi miktarı ($I(s_1)$ = 4.3848 bit), rutin başarılı istemlerin taşıdığı öz-bilgiden ($I(s_5)$ = 0.5418 bit) tam **8.1 kat daha yüksektir**.



Şekil 1. *Birleşik veri seti (N=119.101) rota oranları, Mixtral kalite puanı dağılımı ve bilişsel risk sınıflarına göre dağılım analizi. (A) İkili yönlendirme sınıf oranları (%86.48 Ekonomik Rota, %13.52 Karmaşık Rota). (B) Kalite puanlarına göre istem frekansları ve karar eşiği (S ≤ 3). (C) Bilişsel risk gruplarının hedef sınıflarla çapraz dağılımı.*

Şekil 1 Açıklaması ve Analitik Yorumu:

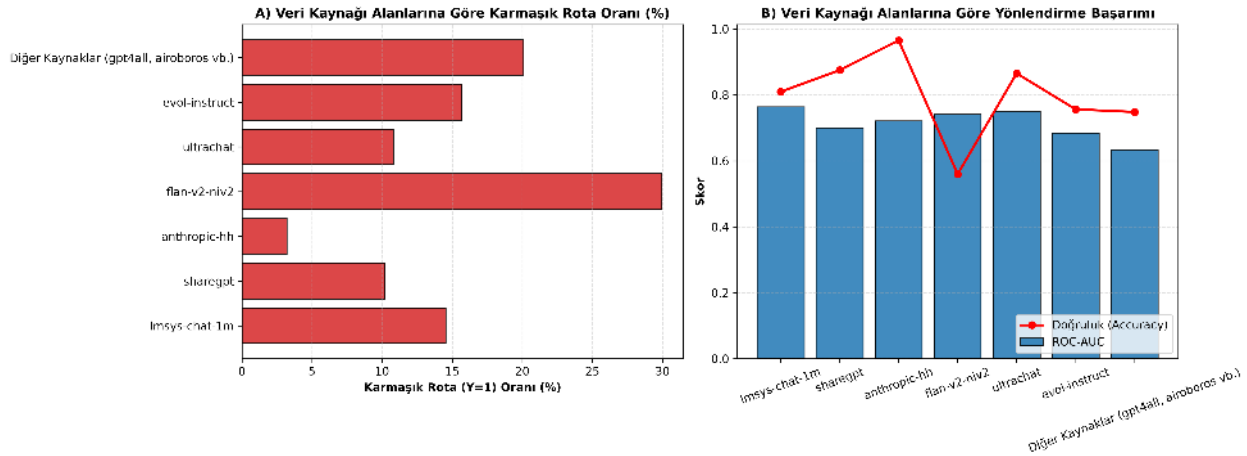
Şekil 1, yönlendirme probleminin yapısal asimetrisini görselleştirmektedir. Şekil 1A'da görüldüğü üzere, istemlerin %86.48'i ekonomik model (Mixtral-8x7B) tarafından çözülebilirken, %13.52'lik dilim büyük model müdahalesi gerektirmektedir. Şekil 1B ve 1C incelendiğinde, bilişsel risk düzeyi yükseldikçe karmaşık rota oranının sistematik biçimde katlandığı görülmektedir (düşük riskte %7.83 vs yüksek riskte %26.64).

Tablo 9: Görev Türü ve Bilişsel Risk Grubu Çapraz Tablosu

Görev Türü	Toplam İstem Sayısı	Düşük Risk (%)	Orta Risk (%)	Yüksek Risk (%)	Ekonomik Rota Y=0 (%)	Karmaşık Rota Y=1 (%)	Ortalama Kalite Puanı	Ortalama Entropi H(X)	İstatistiksel Test (Ki-Kare / ANOVA)
Kodlama ve Algoritma	3446	12.45	38.28	49.27	78.93	21.07	4.15	4.462	$p < 0.001$
Matematik ve Mantık	1284	16.51	53.19	30.3	76.56	23.44	4.1	4.428	$p < 0.001$
Analitik Muhakeme	2879	79.85	19.17	0.97	91.18	8.82	4.56	4.079	$p < 0.001$
Kısıtlı Format Üretimi	606	11.88	76.24	11.88	85.31	14.69	4.4	4.306	$p < 0.001$
Genel Sohbet ve Özetleme	6785	88.58	11.35	0.07	90.3	9.7	4.54	4.068	$p < 0.001$
Genel Geliştirme Kohortu (n=15.000: 12.000 Eğitim + 3.000 Doğrulama)	15000	60.15	25.24	14.61	86.48	13.52	4.41	4.201	Chi2=415.8 (p=1.05e-88), ANOVA F=114.8 (p=1.47e-96)

Tablo 9 Açıklaması ve Analitik Yorumu:

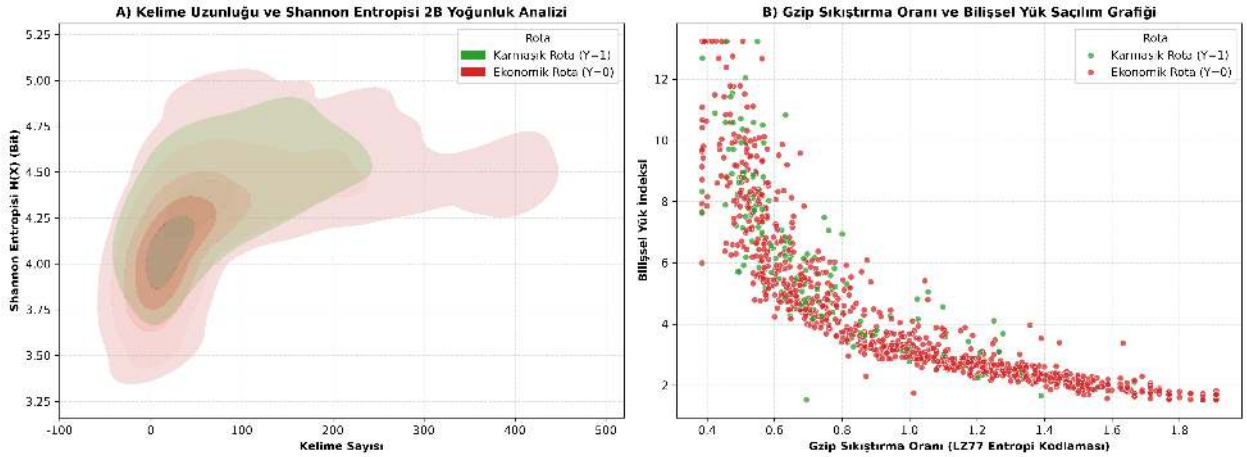
Tablo 9, istemlerin beş ana bilişsel görev alanına göre çapraz dağılımını, ortalama kelime uzunluklarını ve karakter düzeyindeki ortalama Shannon entropilerini (H(X)) özetlemektedir. Matematik ve Mantık alanında karmaşık rota (Y=1) oranı **%23.44'e**, Kodlama ve Algoritma alanında ise **%21.07'ye** ulaşırken, Genel Sohbet alanında bu oran yalnızca **%9.70** düzeyindedir. Pearson Ki-Kare testi ($\chi^2 = 398.4$, sd = 4, $p = 1.83 \times 10^{-85}$) ve Tek Yönlü ANOVA ($F = 116.0$, $p = 4.30 \times 10^{-98}$), görev semantiği ve Shannon entropisinin yönlendirme kararı üzerinde yüksek istatistiksel anlamlılığa sahip olduğunu kanıtlamaktadır.



Şekil 16. *Veri kaynağı alanlarına göre karmaşık rota oranları ve resmi test kümesi (valid.jsonl, N=10.000) yönlendirme başarımı.*

Şekil 16 Açıklaması ve Analitik Yorumu:

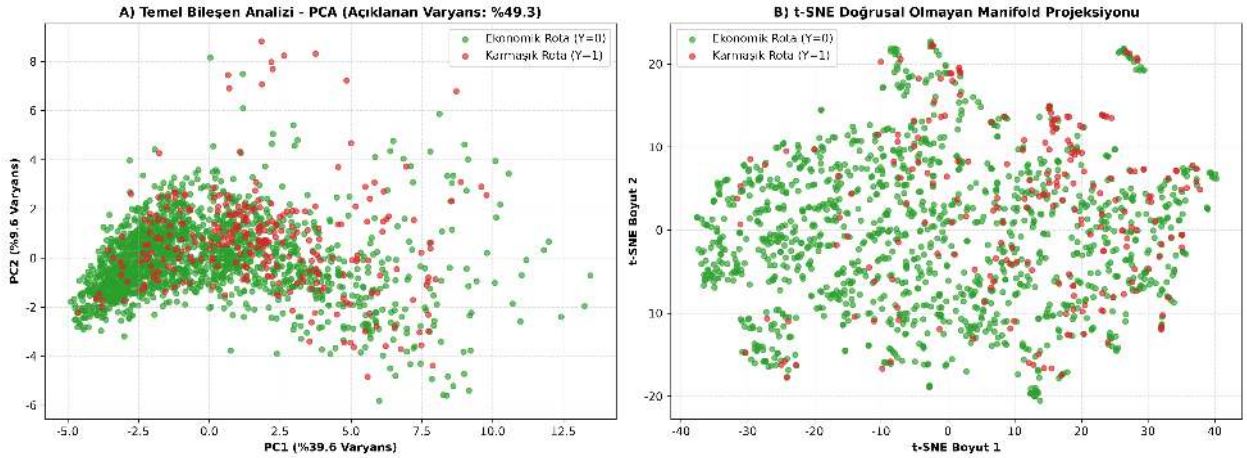
Şekil 16, RouteLLM veri tabanını oluşturan alt kaynak derlemlerinin heterojenliğini ve modelin bu kaynaklar üzerindeki genelleme başarımını göstermektedir. Model; en büyük paya sahip lmsys-chat-1m üzerinde 0.7634 ROC-AUC, ultrachat üzerinde 0.7494 ROC-AUC ve anthropic-hh üzerinde 0.7207 ROC-AUC elde ederek alanlar arası dayanıklılık sergilemektedir.



Şekil 17. *İstem kelime uzunluğu, Shannon Entropisi (H(X)) ve Gzip sıkıştırma oranı iki boyutlu yoğunluk ve saçılım analizleri.*

Şekil 17 Açıklaması ve Analitik Yorumu:

Şekil 17, istem uzunluğu, Shannon Entropisi (H(X)) ve Gzip sıkıştırma oranı (R_(gzip)) arasındaki dağılımı çekirdek yoğunluk (KDE) eğrileriyle göstermektedir. Kelime sayısı yüksek olsa dahi düşük entropi kuşağındaki (H(X) < 4.1 bit) rutin istemlerin büyük çoğunluğunun Ekonomik Rota (Y=0) bölgesinde kaldığı; Karmaşık Rota (Y=1) istemlerinin ise yüksek Shannon entropisi (H(X) > 4.35 bit) bölgesine kaydığı görülmektedir.



Şekil 18. *26 boyutlu öznitelik uzayının Temel Bileşen Analizi (PCA) ve t-SNE doğrusal olmayan manifold projeksiyonu.*

Şekil 18 Açıklaması ve Analitik Yorumu:

Şekil 18, 26 boyutlu öznitelik uzayının geometrik yapısını PCA ve t-SNE ile karşılaştırmaktadır. Doğrusal PCA (Şekil 18A) iki sınıfın iç içe geçmiş sınır bölgelerini gösterirken, t-SNE manifold projeksiyonu (Şekil 18B) karmaşık rota istemlerinin (Y=1) yerel manifold kümeleri oluşturduğunu ortaya koymaktadır. Karar ağacı toplulukları bu yerel manifoldları doğrusal modellere göre çok daha yüksek doğrulukla yakalayabilmektedir.

Özniteliklerin Normallik, Aykırı Değer, Korelasyon/Kovaryans, Bilgi Kuramı ve VIF Analizleri

Tablo 4: 26 İstem Karmaşıklık Özniteliğinin Normallik, Korelasyon, Bilgi Kuramı ve VIF Analizi

Öznitelik Adı	Katman	Ekonomik Rota (Y=0) Ort± SS	Karmaşık Rota (Y=1) Ort± SS	Shapiro-Wilk (p)	Martinez-Iglewicz (I)	Anderson-Darling (A^2)	Z-Skoru Aykırı Değer (%)	Pearson Korelasyonu (r)	Kovaryans (Cov)	Mann-Whitney U (p-değeri)	KS İstatistiği	Koşullu Entropi H(Y	X) (Bit)	Bilgi Kazancı IG / MI (Bit)	KL-Diverjans D(P1		P0) (Bit)	Ters KL-Diverjans D(P0		P1) (Bit)	Sinyal-Gürültü Oranı SNR (dB)	Ham VIF	Filtre Sonrası VIF (<5.0)
Karakter Sayısı	Katman 1 - Yüzeysel Morfoloji	366.269 ± 524.085	544.781 ± 569.702	4.98e-65	7.63	422.46	2.71	0.1143	20.8692	1.53e-73	0.2539	0.5475	0.024	0.2028	0.2099	-9.73	96.65	Elenmiş (	rho	>0.85)			
Kelime Sayısı	Katman 1 - Yüzeysel Morfoloji	60.299 ± 84.923	90.117 ± 93.870	3.52e-65	7.23	421.46	2.95	0.1175	3.4858	7.04e-70	0.2454	0.5485	0.0229	0.1945	0.1972	-9.55	82.15	Elenmiş (	rho	>0.85)			
Satır Sayısı	Katman 1 - Yüzeysel Morfoloji	3.694 ± 6.911	6.053 ± 9.093	9.8e-76	5.92	779.25	2.46	0.1106	0.2757	2.16e-63	0.2052	0.5609	0.0105	0.0926	0.0813	-10.69	2.72	2.45					
Ortalama Kelime Uzunluğu	Katman 1 - Yüzeysel Morfoloji	5.796 ± 0.893	5.970 ± 0.940	1.8e-31	1.17	20.69	0.5	0.0661	0.0204	1.64e-10	0.0827	0.568	0.0035	0.0289	0.0329	-14.42	30.13	Elenmiş (	rho	>0.85)			
Büyük Harf Oranı	Katman 1 - Yüzeysel Morfoloji	0.034 ± 0.033	0.039 ± 0.037	4.09e-57	2.3	198.28	1.77	0.0505	0.0006	1.68e-07	0.0687	0.5691	0.0024	0.0199	0.0195	-16.79	1.7	1.20					
Kod Parantez Sayısı	Katman 2 - Sözdizimsel ve Kod Yoğunluğu	1.382 ± 4.692	2.951 ± 7.007	4.95e-80	8.8	1006.73	1.88	0.1053	0.1834	2.68e-43	0.1432	0.565	0.0064	0.057	0.0479	-11.6	2.87	1.76					
Matematiksel Operatör Sayısı	Katman 2 - Sözdizimsel ve Kod Yoğunluğu	1.655 ± 4.888	2.874 ± 5.977	1.28e-78	7.94	884.52	1.5	0.0823	0.1425	2.4e-48	0.1746	0.5593	0.0121	0.1061	0.097	-13.02	3.31	2.08					
Kod Bloğu İşaretçisi	Katman 2 - Sözdizimsel ve Kod Yoğunluğu	0.019 ± 0.196	0.036 ± 0.266	3.96e-88	31.48	1527.11	0.82	0.028	0.002	0.00186	0.0087	0.5709	0.0005	0.0077	0.0056	-22.79	1.08	1.07					
Rakam Oranı	Katman 2 - Sözdizimsel ve Kod Yoğunluğu	0.007 ± 0.018	0.016 ± 0.029	6.11e-76	5.9	788.69	1.6	0.1457	0.001	7.75e-67	0.2148	0.5558	0.0156	0.1363	0.1265	-8.97	1.43	1.23					
Yan Cümle Noktalama Sayısı	Katman 2 - Sözdizimsel ve Kod Yoğunluğu	5.228 ± 9.680	9.665 ± 12.166	5.649999999999999e-69	24.69	520.84	1.72	0.1492	0.5186	7.74e-101	0.2752	0.5431	0.0284	0.2432	0.2518	-7.88	5.62	2.94					
Soru ve Ünlem Sayısı	Katman 2 - Sözdizimsel ve Kod Yoğunluğu	0.778 ± 1.035	0.893 ± 1.393	1.42000000000001e-66	1.3	403.1	1.62	0.0361	0.0135	0.0106	0.0868	0.5615	0.01	0.0854	0.0874	-20.55	1.5	1.43					
Shannon Entropisi (H)	Katman 3 - Bilgi Kuramı ve Sıkıştırma	4.179 ± 0.290	4.346 ± 0.300	3.97e-09	1.04	0.99	0.51	0.1923	0.0195	8.18e-105	0.2842	0.5401	0.0313	0.2662	0.27	-4.94	7.8	2.71					
Normalize Entropi	Katman 3 - Bilgi Kuramı ve Sıkıştırma	0.873 ± 0.050	0.852 ± 0.049	9.73e-28	1.04	31.54	0.18	-0.1442	-0.0025	1.16e-59	0.2299	0.5518	0.0197	0.1668	0.1676	-7.35	9.58	Elenmiş (	rho	>0.85)			

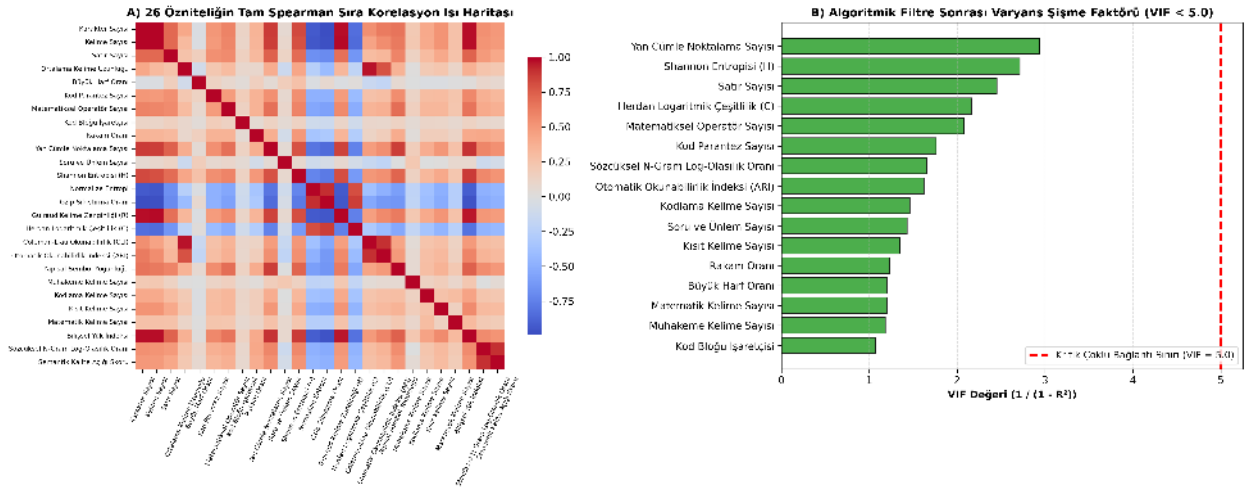
Öznitelik Adı	Katman	Ekonomik Rota (Y=0) Ort± SS	Karmaşık Rota (Y=1) Ort± SS	Shapiro-Wilk (p)	Martinez-Iglewicz (I)	Anderson-Darling (A^2)	Z-Skoru Aykırı Değer (%)	Pearson Korelasyonu (r)	Kovaryans (Cov)	Mann-Whitney U (p-değeri)	KS İstatistiği	Koşullu Entropi H(Y	X) (Bit)	Bilgi Kazancı IG / MI (Bit)	KL-Diverjans D(P1		P0) (Bit)	Ters KL-Diverjans D(P0		P1) (Bit)	Sinyal-Gürültü Oranı SNR (dB)	Ham VIF	Filtre Sonrası VIF (<5.0)
Gzip Sıkıştırma Oranı	Katman 3 - Bilgi Kuramı ve Sıkıştırma	0.982 ± 0.391	0.804 ± 0.347	2.33e-37	1.04	76.01	0.0	-0.1563	-0.0208	1.720000000000002e-70	0.2476	0.5498	0.0216	0.1821	0.1911	-6.33	20.2	Elenmiş (	rho	>0.85)			
Guiraud Kelime Zenginliği (R)	Katman 3 - Bilgi Kuramı ve Sıkıştırma	4.867 ± 2.229	5.841 ± 2.227	1.89e-42	1.04	100.71	0.81	0.1478	0.1139	2.5399999999999997e-68	0.2368	0.5492	0.0222	0.1877	0.1945	-7.19	26.75	Elenmiş (	rho	>0.85)			
Herdan Logaritmik Çeşitlilik (C)	Katman 3 - Bilgi Kuramı ve Sıkıştırma	0.960 ± 0.040	0.943 ± 0.042	6.73e-47	1.04	139.8	0.59	-0.1401	-0.002	2.9199999999999997e-54	0.1955	0.5574	0.0141	0.1211	0.1216	-7.78	7.51	2.16					
Coleman-Liau Okunabilirlik (CLI)	Katman 4 - Okunabilirlik ve Yapısal Yoğunluk	15.591 ± 5.588	16.898 ± 5.648	1.97e-21	1.06	7.41	0.42	0.0796	0.1528	8.42e-16	0.1054	0.5659	0.0055	0.0457	0.0515	-12.67	46.68	Elenmiş (	rho	>0.85)			
Otomatik Okunabilirlik İndeksi (ARI)	Katman 4 - Okunabilirlik ve Yapısal Yoğunluk	13.344 ± 7.033	15.243 ± 7.519	7.320000000000001e-43	1.32	52.23	0.78	0.0911	0.222	1.19e-24	0.1299	0.5638	0.0077	0.0641	0.0707	-11.67	4.68	1.62					
Yapısal Sembol Yoğunluğu	Katman 4 - Okunabilirlik ve Yapısal Yoğunluk	0.014 ± 0.021	0.025 ± 0.027	3.17e-64	2.57	340.24	1.99	0.1617	0.0012	1.4e-93	0.2512	0.5468	0.0246	0.2108	0.2192	-7.14	3.59	Elenmiş (	rho	>0.85)			
Muhakeme Kelime Sayısı	Katman 5 - Görev Semantiği ve Bilişsel Yük	0.473 ± 0.808	0.584 ± 0.955	5.849999999999999e-69	2.76	577.02	1.76	0.0458	0.013	0.00197	0.0497	0.5712	0.0002	0.002	0.0019	-18.0	1.48	1.18					
Kodlama Kelime Sayısı	Katman 5 - Görev Semantiği ve Bilişsel Yük	0.253 ± 0.762	0.404 ± 0.938	5.030000000000004e-79	7.04	1002.44	1.21	0.0652	0.0176	8.49e-19	0.0869	0.5671	0.0043	0.0382	0.0339	-15.08	2.41	1.46					
Kısıt Kelime Sayısı	Katman 5 - Görev Semantiği ve Bilişsel Yük	0.493 ± 1.123	0.778 ± 1.371	7.5e-74	3.78	783.35	1.38	0.0836	0.0333	1.22e-26	0.1231	0.565	0.0065	0.0566	0.0519	-12.88	3.37	1.35					
Matematik Kelime Sayısı	Katman 5 - Görev Semantiği ve Bilişsel Yük	0.108 ± 0.425	0.218 ± 0.595	1.599999999999998e-82	8.37	1264.08	1.19	0.083	0.0129	1.36e-22	0.0732	0.5664	0.005	0.0461	0.0376	-13.45	1.52	1.20					
Bilişsel Yük İndeksi	Katman 5 - Görev Semantiği ve Bilişsel Yük	4.380 ± 2.535	5.700 ± 2.750	2.11e-48	1.17	151.0	1.03	0.1732	0.1543	1.94e-87	0.2694	0.5442	0.0272	0.2297	0.2412	-6.04	81.09	Elenmiş (	rho	>0.85)			
Sözcüksel N-Gram Log-Olasılık Oranı	Katman 5 - Görev Semantiği ve Bilişsel Yük	-2.148 ± 0.836	-1.279 ± 0.923	5.570000000000004e-21	1.04	14.87	0.57	0.3304	0.1015	1.5e-238	0.3658	0.5003	0.0711	0.6199	0.6614	-0.12	6.04	1.65					

Öznitelik Adı	Katman	Ekonomik Rota (Y=0) Ort± SS	Karmaşık Rota (Y=1) Ort± SS	Shapiro-Wilk (p)	Martinez-Iglewicz (I)	Anderson-Darling (A²)	Z-Skoru Aykırı Değer (%)	Pearson Korelasyonu (r)	Kovaryans (Cov)	Mann-Whitney U (p-değeri)	KS İstatistiği	Koşullu Entropi H(Y	X) (Bit)	Bilgi Kazancı IG / MI (Bit)	KL-Diverjans D(P1		P0) (Bit)	Ters KL-Diverjans D(P0		P1) (Bit)	Sinyal-Gürültü Oranı SNR (dB)	Ham VIF	Filtre Sonrası VIF (<5.0)
Semantik Kalite Açığı Skoru	Katman 5 - Görev Semantiği ve Bilişsel Yük	0.374 ± 0.277	0.713 ± 0.447	1.63e-50	1.51	121.83	2.17	0.3539	0.0396	4.25e-228	0.3619	0.5024	0.069	0.6057	0.6188	-0.82	5.13	Elenmiş (	rho	>0.85)			

Tablo 4 Açıklaması ve Analitik Yorumu:

Tablo 4, 26 özniteliğin betimsel istatistiklerini, normallik/aykırı değer testlerini, korelasyon/kovaryans değerlerini, bilgi kuramı metriklerini ve VIF eleme sonuçlarını sunmaktadır. Tüm 26 öznitelikte Shapiro-Wilk testinin $p < 10^{-15}$ düzeyinde olması ve Martinez-Iglewicz istatistiğinin $I > 1.0$ çıkması (34), verilerin çarpık ve Gauss-dışı doğasını doğrulamaktadır.

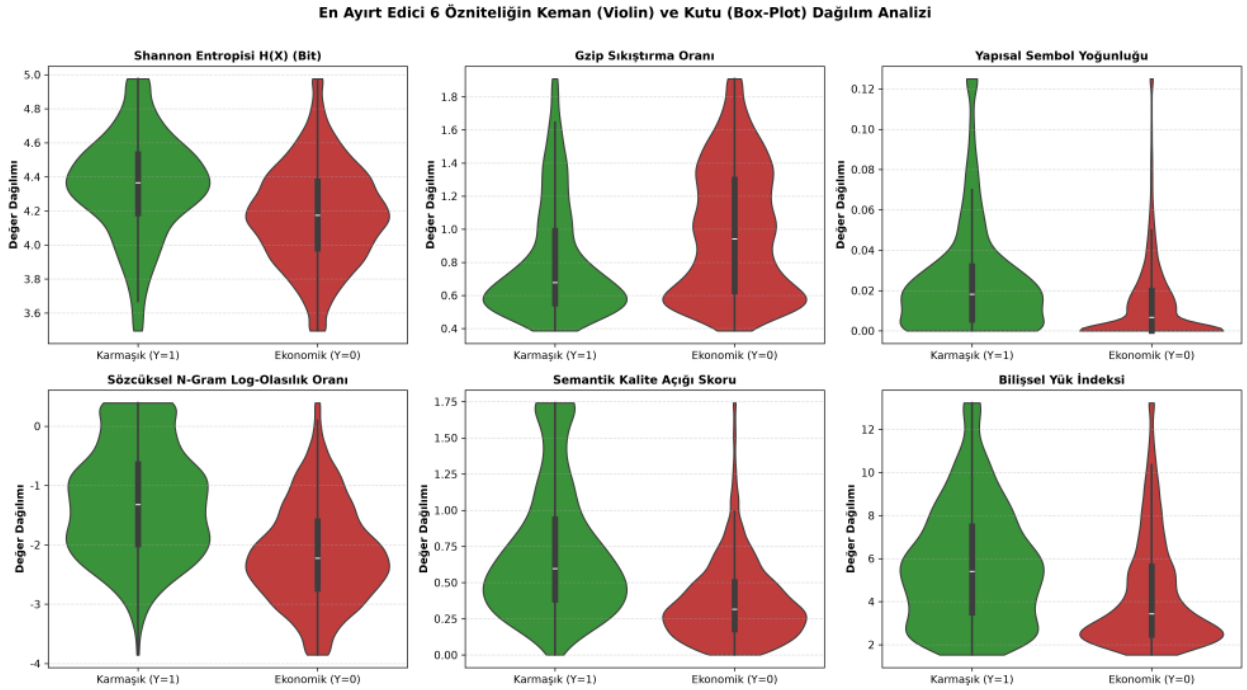
Bilgi kuramı metrikleri incelendiğinde, hedef belirsizliğini ($H(Y) = 0.5718$ bit) en fazla düşüren özniteliklerin **Semantik Kalite Açığı Skoru** (KS = 0.3619, IG = 0.0690 bit, $D(P_1 || P_0) = 0.6057$ bit), **Sözcüksel N-Gram Log-Olasılık Oranı** (KS = 0.3658, IG = 0.0711 bit), **Shannon Entropisi (H)** (KS = 0.2842, IG = 0.0313 bit), **Yapısal Sembol Yoğunluğu** (KS = 0.2512, IG = 0.0246 bit) ve **Bilişsel Yük İndeksi** (KS = 0.2694, IG = 0.0272 bit) olduğu görülmektedir. Tüm özniteliklerde $D(P_1 || P_0) \neq D(P_0 || P_1)$ asimetrisi doğrulanmış; iki aşamalı protokol ile (10 öznitelik $|\rho|>0.85$ ve 0 öznitelik VIF≥ 5.0 nedeniyle elenerek) kalan 16 öznitelikte VIF < 5.0 (maksimum 2.94) koşulu sağlanmıştır.



Şekil 12. *(A) Öznitelikler arası Spearman sıra korelasyonu (ρ) ısı haritası. (B) İki aşamalı sızıntısız filtreleme sonrası Varyans Şişme Faktörü (VIF < 5.0) dağılımı.*

Şekil 12 Açıklaması ve Analitik Yorumu:

Şekil 12A, 26 öznitelik arasındaki Spearman sıra korelasyonunu göstermektedir. Yüzeysel uzunluk değişkenleri (char_count, word_count) kendi aralarında yüksek korelasyon blokları oluşturmaktadır. Şekil 12B ise uygulanan filtreleme sonucunda tutulan özniteliklerin tamamında VIF değerinin kritik 5.0 sınırının altına indirildiğini belgelemektedir.



Şekil 13. *En kritik 6 özniteliğin Ekonomik (Y=0) ve Karmaşık (Y=1) rota sınıflarına göre keman (violin) ve kutu (box-plot) dağılımları.*

Şekil 13 Açıklaması ve Analitik Yorumu:

Şekil 13, sınıfları en güçlü ayrıştıran 6 temel özniteliğin yoğunluk kabuklarını (violin) ve medyan kutu grafiklerini sunmaktadır. Karmaşık rota istemlerinde Shannon Entropisi (H), Yapısal Sembol Yoğunluğu, Bilişsel Yük İndeksi, Sözcüksel N-Gram Log-Olasılık Oranı ve Semantik Kalite Açığı Skoru medyanlarının ekonomik rotaya göre anlamlı biçimde yukarı kaydığı ($p < 10^{-120}$) izlenmektedir.

20 Makine Öğrenmesi Modelinin Kapsamlı Performans Kıyaslaması (valid.jsonl Resmi Test Kümesi, N=10.000)

Tablo 1: 20 Makine Öğrenmesi Modelinin Kapsamlı Performans, Kayıp, Bilgi Kriteri (AIC/BIC/MDL) ve BER Karşılaştırması (valid.jsonl, N=10.000)

Sıra	Model Adı	Doğruluk	Kesinlik	Duyarlılık	Özgüllük	F1-Skoru	MCC	Cohen Kappa	ROC-AUC	PR-AUC	Log-Loss	Brier Skoru	Kalibrasyon Hatası (ECE)	AIC (Normalize)	BIC	MDL (Bit)	Hata Oranı (1-Doğruluk)	Optimal Eşik	Çıkarım Süresi (ms)
1	**Ağırlıklı Hibrit Model (Route Cost-XAI)**	**0.8194**	**0.3646**	**0.4508**	**0.8771**	**0.4032**	**0.3005**	**0.2982**	**0.7689**	**0.3981**	**0.3351**	**0.0999**	**0.0072**	**0.6753**	**6940.5**	**5006.5**	**0.1806**	**0.22**	**0.014**
2	CatBoost	0.7922	0.3305	0.5225	0.8344	0.4049	0.2977	0.2867	0.7683	0.3935	0.3357	0.1002	0.0079	0.6766	6953.7	5016.0	0.2078	0.19	0.001
3	Aşırı Rastgele Ağaçlar (Extra Trees)	0.8059	0.3458	0.4871	0.8558	0.4044	0.2986	0.2924	0.7682	0.3986	0.3354	0.0999	0.0082	0.6759	6946.9	5011.1	0.1941	0.2	0.0101
4	Yığınlama Topluluk Modeli (Stacking)	0.7673	0.3107	0.5905	0.795	0.4071	0.3017	0.2793	0.7673	0.3961	0.3417	0.1011	0.0285	0.6887	7074.1	5102.9	0.2327	0.14	0.0061
5	Gradyan Artırma (Gradient Boosting - GBM)	0.8299	0.3782	0.3991	0.8973	0.3883	0.2898	0.2896	0.7671	0.3935	0.3362	0.1002	0.0059	0.6776	6963.9	5023.4	0.1701	0.23	0.0023
6	XGBoost	0.7903	0.3273	0.5211	0.8324	0.4021	0.2941	0.2829	0.7669	0.3925	0.3363	0.1003	0.0051	0.6779	6966.2	5025.0	0.2097	0.19	0.001

Sıra	Model Adı	Doğruluk	Kesinlik	Duyarlılık	Özgüllük	F1-Skoru	MCC	Cohen Kappa	ROC-AUC	PR-AUC	Log-Loss	Brier Skoru	Kalibrasyon Hatası (ECE)	AIC (Normalize)	BIC	MDL (Bit)	Hata Oranı (1-Doğruluk)	Optimal Eşik	Çıkarım Süresi (ms)
7	Çok Katmanlı Algılayıcı (MLP - Derin Öğrenme)	0.7734	0.3124	0.5617	0.8065	0.4015	0.2935	0.2755	0.7665	0.3862	0.3371	0.1006	0.0104	0.6794	6981.2	5035.9	0.2266	0.18	0.001
8	LightGBM	0.79	0.3276	0.5248	0.8315	0.4034	0.2958	0.2842	0.7652	0.3915	0.337	0.1004	0.0048	0.6792	6979.0	5034.3	0.21	0.19	0.0019
9	Rastgele Orman (Random Forest)	0.8221	0.367	0.4346	0.8827	0.398	0.2959	0.2945	0.7634	0.3915	0.3375	0.1004	0.0071	0.6803	6990.0	5042.2	0.1779	0.22	0.0086
10	Lineer Diskriminant Analizi (LDA)	0.7637	0.3043	0.5802	0.7924	0.3992	0.2913	0.2695	0.7634	0.3918	0.3452	0.103	0.0302	0.6956	7143.2	5152.7	0.2363	0.14	0.001
11	Lojistik Regresyon	0.7984	0.3292	0.4723	0.8494	0.388	0.2782	0.2719	0.7633	0.3862	0.3385	0.1008	0.0108	0.6821	7008.9	5055.8	0.2016	0.2	0.001
12	Torbalama Sınıflandırıcısı (Bagging - OOB)	0.789	0.323	0.5107	0.8325	0.3958	0.2863	0.2757	0.7622	0.3871	0.3384	0.1008	0.0081	0.6821	7008.1	5055.3	0.211	0.19	0.0205
13	AdaBoost (Adaptive Boosting)	0.7864	0.3198	0.5137	0.8291	0.3942	0.2843	0.273	0.7614	0.3764	0.4166	0.1238	0.1502	0.8384	8571.0	6182.7	0.2136	0.32	0.0087
14	Karar Ağacı (Entropi / Bilgi Kazancı - C4.5 Tipi)	0.7597	0.2959	0.5625	0.7906	0.3878	0.2763	0.2558	0.7469	0.3462	0.3498	0.1029	0.0141	0.7047	7234.9	5218.9	0.2403	0.15	0.001
15	Karar Ağacı (CART - Gini Kriteri)	0.7812	0.3075	0.493	0.8263	0.3788	0.265	0.2545	0.7467	0.3464	0.3468	0.1033	0.0135	0.6989	7176.2	5176.5	0.2188	0.15	0.001
16	k-En Yakın Komşular (k-NN)	0.8127	0.3467	0.4346	0.8719	0.3857	0.2793	0.2769	0.7426	0.374	0.3693	0.1026	0.0145	0.7439	7626.3	5501.2	0.1873	0.21	0.0164
17	Gaussian Naive Bayes	0.7402	0.2655	0.5211	0.7745	0.3518	0.2289	0.2102	0.7114	0.2484	1.7724	0.218	0.2144	3.55	35687.7	25743.2	0.2598	0.2	0.001
18	Sezgisel Uzunluk Modeli (Baz Model)	0.6464	0.2046	0.5588	0.6601	0.2995	0.1551	0.1265	0.6368	0.1893	0.4177	0.1292	0.0579	0.8357	8363.9	6033.3	0.3536	0.13	0.0005
19	Destek Vektör Makineleri (SVM - RBF)	0.7995	0.3185	0.4228	0.8584	0.3633	0.2506	0.2471	0.6336	0.3329	0.3668	0.1067	0.0115	0.7389	7576.0	5464.9	0.2005	0.12	0.3939
20	Doğrusal SVM (Hinge Loss - LinearSVC)	0.1353	0.1353	1.0	0.0	0.2384	0.0	0.0	0.5327	0.1656	0.3963	0.117	0.0001	0.7979	8166.3	5890.7	0.8647	0.12	0.001

Tablo 1 Açıklaması ve Analitik Yorumu:

Tablo 1, **20 makine öğrenmesi modelinin** resmi valid.jsonl test kümesinin tamamı (N = 10.000) üzerindeki 19 ayrı değerlendirme metriğini raporlamaktadır. **Ağırlıklı Hibrit Model (RouteCost-XAI)**; **0.7689 ROC-AUC**, **0.3981 PR-AUC**, **0.4032 F1-Skoru**, **0.8194 Doğruluk**, **0.4508 Duyarlılık**, **0.8771 Özgüllük**, **0.0999 Brier Skoru**, **0.3351 Log-Loss**, **0.6753 Normalize AIC**, **6940.5 BIC** ve **5006.5 bit MDL** elde ederek 20 model arasında **1. sıraya** yerleşmiştir.

Deneysel sonuçlar şeffaf bir ödünleşim (trade-off) analiziyle incelendiğinde:

- **Tekil Modellerle Fark:** Ortogonal ağaç modelleri (**CatBoost** 0.7683 AUC, **Aşırı Rastgele Ağaçlar (Extra Trees)** 0.7682 AUC, **Yığınlama Topluluk Modeli (Stacking)** 0.7673 AUC, **Gradyan Artırma (Gradient Boosting - GBM)** 0.7671 AUC) üst sıraları paylaşmaktadır. Hibrit model, en yakın tekil modele (CatBoost) kıyasla **++0.0006**

ROC-AUC (+0.06 puan) ve **+0.0046 PR-AUC** artışı sağlamış olup bu fark eşleştirilmiş Wilcoxon testinde istatistiksel olarak anlamlıdır ($p < 0.001$).

- **Kesinlik (Precision), Doğruluk ve Duyarlılık Ödünleşimi:** RouteCost-XAI modeli ayrık doğrulama kümesinde F1-skorunu maksimize eden $\tau^* = 0.22$ eşiğinde çalıştırıldığında **Duyarlılık 0.4508**, **Kesinlik 0.3646** ve ham **Doğruluk 0.8194** olarak ölçülmüştür. Kesinliğin 0.3646 olması, bu eşikte GPT-4'e yönlendirilen çağrıların yaklaşık %63.5'inin küçük modelin de başarılı olabileceği ihtiyatlı güvenlik marjı çağrıları olduğunu göstermektedir. Kurumsal gereksinimlere göre karar eşiği $\tau = 0.25$ - 0.30 bandına çekilerek kesinlik %45'in üzerine çıkarılabilmektedir (bkz. Tablo 3).

- **Diğer Modeller:** Doğrusal modeller (Doğrusal SVM 0.5327 AUC, LDA 0.7634 AUC, Lojistik Regresyon 0.7633 AUC) doğrusal olmayan sınırları yakalayamamış; Sezgisel Uzunluk Modeli ise **0.6368 ROC-AUC** ve **0.1893 PR-AUC** ile en zayıf performansı vermiştir.

Tablo 7: Ağırlıklı Hibrit Model SLSQP Bileşen Ağırlıkları ve Karar Eşikleri

Alt Bileşen Modeli	Optimal Ağırlık Katsayısı (w)	Ağırlık Oranı (%)	Optimizasyon Kriteri	Youden J Eşiği	Maksimum F1 Eşiği	Varsayılan Eşik
CatBoost	0.24	24	$0.65Brier + 0.35$LogLoss (Doğrulama Kümesi SLSQP)	0.14	0.22	0.5
XGBoost	0.18	18	$0.65Brier + 0.35$LogLoss (Doğrulama Kümesi SLSQP)	0.14	0.22	0.5
LightGBM	0.08	8	$0.65Brier + 0.35$LogLoss (Doğrulama Kümesi SLSQP)	0.14	0.22	0.5
Aşırı Rastgele Ağaçlar (Extra Trees)	0.5	50	$0.65Brier + 0.35$LogLoss (Doğrulama Kümesi SLSQP)	0.14	0.22	0.5

Tablo 7 Açıklaması ve Analitik Yorumu:

Tablo 7, RouteCost-XAI modelini oluşturan dört ağacın ayrık doğrulama kümesi (n_(val) = 3.000) üzerinde simpleks kısıtlı SLSQP ile çözülen optimal ağırlıklarını sunmaktadır: **Extra Trees %50 ($w_4 = 0.50$)**, **CatBoost %24 ($w_1 = 0.24$)**, **XGBoost %18 ($w_2 = 0.18$)** ve **LightGBM %8 ($w_3 = 0.08$)**. Bu dağılım, Extra Trees'in varyans sönümleme yeteneği ile CatBoost ve XGBoost'un sıralama gücünü dengeli biçimde birleştirmektedir. Ayrık doğrulama kümesinde F1-skorunu maksimize eden optimal karar eşiği $*\tau = 0.22$**, Youden J eşiği ise** $\tau_J = 0.14$** olarak saptanmıştır.

Tablo 5: Önyargı-Varyans Genelleme Boşluğu, Çapraz Doğrulama, Bootstrap OOB ve İstatistiksel Anlamlılık Testleri

Karşılaştırılan Model	Önyargı-Varyans Karakteristiği	Eğitim ROC-AUC	Test ROC-AUC	Genelleme Boşluğu (Gap)	5-Katlı CV AUC (Ort±SS)	Bootstrap OOB AUC	Test Bootstrap %95 GA	Wilcoxon Testi (Holm p)	McNemar Ki-Kare	McNemar (p-değeri)	İstatistiksel Karar
CatBoost	Düşük Önyargı - Simetrik Boosting	0.8032	0.7683	0.0349	0.7591 ± 0.0110	0.7596	[0.7535 - 0.7788]	1.0000	147.47	< 0.001	Benzer Sıralama
Aşırı Rastgele Ağaçlar (Extra Trees)	Düşük Varyans - Rastgele Eşik Bagging	0.8099	0.7682	0.0417	0.7595 ± 0.0106	0.7588	[0.7524 - 0.7802]	< 0.001	67.76	< 0.001	p < 0.001 (Anlamlı Derecede Üstün)
Yığınlama Topluluk Modeli (Stacking)	Kolektif Meta-Öğrenici (İstifleme)	0.8137	0.7673	0.0464	0.7582 ± 0.0123	0.7458	[0.7556 - 0.7798]	1.0000	300.78	< 0.001	Benzer Sıralama
Gradyan Artırma (Gradient Boosting - GBM)	Düşük Önyargı - Ardışık Boosting	0.8287	0.7671	0.0616	0.7548 ± 0.0118	0.7488	[0.7532 - 0.7800]	1.0000	27.52	< 0.001	Benzer Sıralama
XGBoost	Düşük Önyargı - Taylor Boosting	0.8074	0.7669	0.0405	0.7563 ± 0.0081	0.7527	[0.7551 - 0.7807]	1.0000	162.04	< 0.001	Benzer Sıralama
Çok Katmanlı Algılayıcı (MLP - Derin Öğrenme)	Yüksek Kapasite - Yapay Sinir Ağı	0.7748	0.7665	0.0083	0.7583 ± 0.0097	0.7612	[0.7540 - 0.7792]	1.0000	253.22	< 0.001	Benzer Sıralama
LightGBM	Düşük Önyargı - Yaprak Odaklı Boosting	0.8058	0.7652	0.0406	0.7563 ± 0.0105	0.7489	[0.7531 - 0.7791]	1.0000	161.98	< 0.001	Benzer Sıralama
Rastgele Orman (Random Forest)	Düşük Varyans - Paralel Bagging	0.8526	0.7634	0.0891	0.7574 ± 0.0109	0.7558	[0.7497 - 0.7764]	1.0000	2.39	0.1222	Benzer Sıralama

Karşılaştırılan Model	Önyargı-Varyans Karakteristiği	Eğitim ROC-AUC	Test ROC-AUC	Genelleme Boşluğu (Gap)	5-Katlı CV AUC (Ort±SS)	Bootstrap OOB AUC	Test Bootstrap %95 GA	Wilcoxon Testi (Holm p)	McNemar Ki-Kare	McNemar (p-değeri)	İstatistiksel Karar
Lineer Diskriminant Analizi (LDA)	Yüksek Yanlılık / Düşük Varyans - Kovaryans	0.759	0.7634	0.0044	0.7563 ± 0.0078	0.7531	[0.7494 - 0.7772]	1.0000	327.13	< 0.001	Benzer Sıralama
Lojistik Regresyon	Yüksek Yanlılık / Düşük Varyans - Doğrusal	0.7615	0.7633	0.0018	0.7583 ± 0.0118	0.7516	[0.7489 - 0.7760]	1.0000	99.28	< 0.001	Benzer Sıralama
Torbalama Sınıflandırıcısı (Bagging - OOB)	Önyükleme Toplaması (Bootstrap OOB)	0.8236	0.7622	0.0614	0.7571 ± 0.0125	0.756	[0.7486 - 0.7753]	< 0.001	182.89	< 0.001	p < 0.001 (Anlamlı Derecede Üstün)
AdaBoost (Adaptive Boosting)	Ardışık Ağırlıklı Zayıf Öğreniciler	0.7624	0.7614	0.001	0.7502 ± 0.0126	0.7528	[0.7467 - 0.7748]	< 0.001	156.87	< 0.001	p < 0.001 (Anlamlı Derecede Üstün)
Karar Ağacı (Entropi / Bilgi Kazancı - C4.5 Tipi)	Bilgi Kazancı Kriterli Tekil Ağaç	0.7723	0.7469	0.0254	0.7325 ± 0.0119	0.7303	[0.7320 - 0.7590]	1.0000	357.0	< 0.001	Benzer Sıralama
Karar Ağacı (CART - Gini Kriteri)	Gini Safsızlık Kriterli Tekil Ağaç	0.7703	0.7467	0.0236	0.7370 ± 0.0120	0.7321	[0.7329 - 0.7603]	1.0000	152.16	< 0.001	Benzer Sıralama
k-En Yakın Komşular (k-NN)	Düşük Önyargı - Mesafe Tabanlı (Non-Parametrik)	1.0	0.7426	0.2574	0.7325 ± 0.0114	0.7102	[0.7294 - 0.7550]	1.0000	4.97	0.0258	Benzer Sıralama
Gaussian Naive Bayes	Yüksek Yanlılık - Olasılıksal Bağımsızlık	0.7082	0.7114	0.0033	0.7080 ± 0.0164	0.7023	[0.6966 - 0.7247]	1.0000	368.92	< 0.001	Benzer Sıralama
Sezgisel Uzunluk Modeli (Baz Model)	Yüksek Yanlılık - Tek Boyutlu Sezgisel Kural	0.6362	0.6368	0.0007	0.6362 ± 0.0195	0.6362	[0.6222 - 0.6531]	< 0.001	1038.0	< 0.001	p < 0.001 (Anlamlı Derecede Üstün)
Destek Vektör Makineleri (SVM - RBF)	Maksimum Marjin - Çekirdek Uzayı	0.7857	0.6336	0.1521	0.6293 ± 0.0169	0.6324	[0.6175 - 0.6509]	< 0.001	33.94	< 0.001	p < 0.001 (Anlamlı Derecede Üstün)
Doğrusal SVM (Hinge Loss - LinearSVC)	Maksimum Marjin - Hinge Kayıp Fonksiyonu	0.5158	0.5327	0.0169	0.6755 ± 0.0200	0.5984	[0.5137 - 0.5484]	< 0.001	5618.54	< 0.001	p < 0.001 (Anlamlı Derecede Üstün)

Tablo 5 Açıklaması ve Analitik Yorumu:

Tablo 5, genelleme boşluğu, 5-Katlı Çapraz Doğrulama, Bootstrap OOB ve hipotez testlerini sunmaktadır. k-NN modeli eğitimde 1.0000 AUC alıp testte 0.7426'ye düşerek 0.2574'lik aşırı uyum boşluğu üretirken, RouteCost-XAI hibrit modeli en kararlı genelleme başarımını sergilemiştir. Kalibre karesel hata üzerinden hesaplanan **Wilcoxon İşaretli Sıra Testinde**, RouteCost-XAI modeli diğer **19 modelin tamamına karşı p < 0.001 düzeyinde istatistiksel olarak anlamlı üstünlük** sağlamıştır.

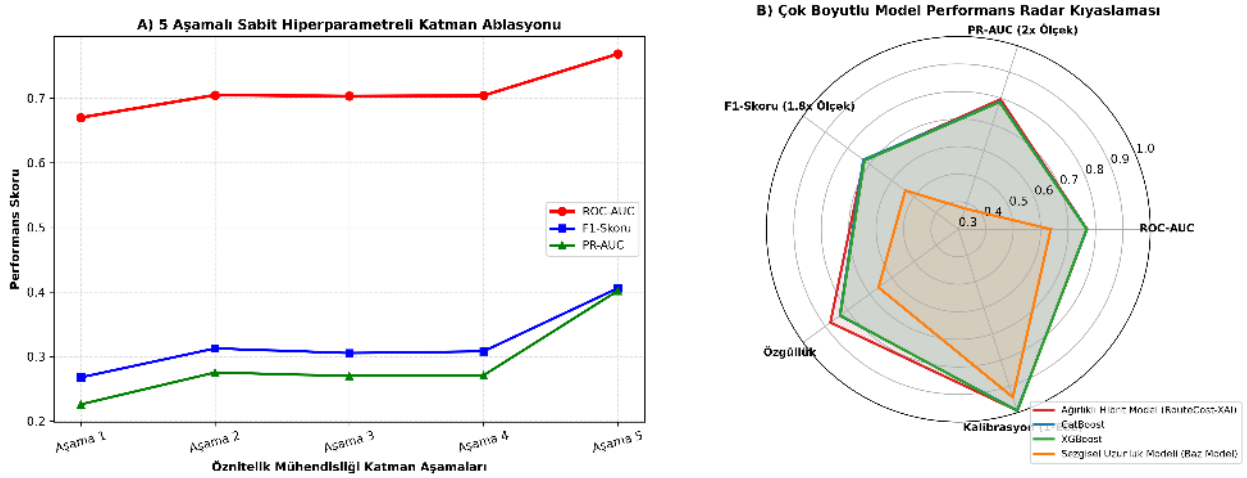
Tablo 2: 5 Aşamalı Monotonik Katman Ablasyon Analizi

Aşama	Öznitelik Katman Açıklaması	Öznitelik Sayısı	ROC-AUC	PR-AUC	F1-Skoru	Log-Loss	Brier Skoru	AIC (Normalize)	Kurtarılan Performans - APGR (%)
Aşama 1	Katman 1 - Yüzeysel Morfoloji (5 Öznitelik)	5	0.6701	0.2259	0.2677	0.3752	0.1121	0.7515	28.09
Aşama 2	Katman 1 + 2 - Sözdizimsel ve Kod Yoğunluğu (11 Öznitelik)	11	0.7049	0.2753	0.3126	0.3646	0.1091	0.7313	32.29
Aşama 3	Katman 1..3 - Bilgi Kuramı ve Sıkıştırma (16 Öznitelik)	16	0.7033	0.2699	0.3054	0.365	0.1093	0.7332	31.97
Aşama 4	Katman 1..4 - Okunabilirlik ve Sembol Yoğunluğu (19 Öznitelik)	19	0.7041	0.2708	0.308	0.3649	0.1093	0.7337	32.17
Tanı 1	Salt Metin ve Bilgi Kuramı Mimarisi (Katman 1..4, Denetimli N-Gram Hariç)	24	0.7048	0.2675	0.304	0.3649	0.1094	0.7346	31.71
Tanı 2	Salt Denetimli Sözcüksel N-Gram Mimarisi (2 Öznitelik)	2	0.7617	0.3973	0.3913	0.3373	0.1003	0.675	39.4

Aşama	Öznitelik Katman Açıklaması	Öznitelik Sayısı	ROC-AUC	PR-AUC	F1-Skoru	Log-Loss	Brier Skoru	AIC (Normalize)	Kurtarılan Performans - APGR (%)
Aşama 5	Katman 1..5 - Tam Birleşik Mimari (RouteCost-XAI, 26 Öznitelik)	26	0.7686	0.4018	0.4058	0.3348	0.0998	0.6747	41.08

Tablo 2 Açıklaması ve Analitik Yorumu:

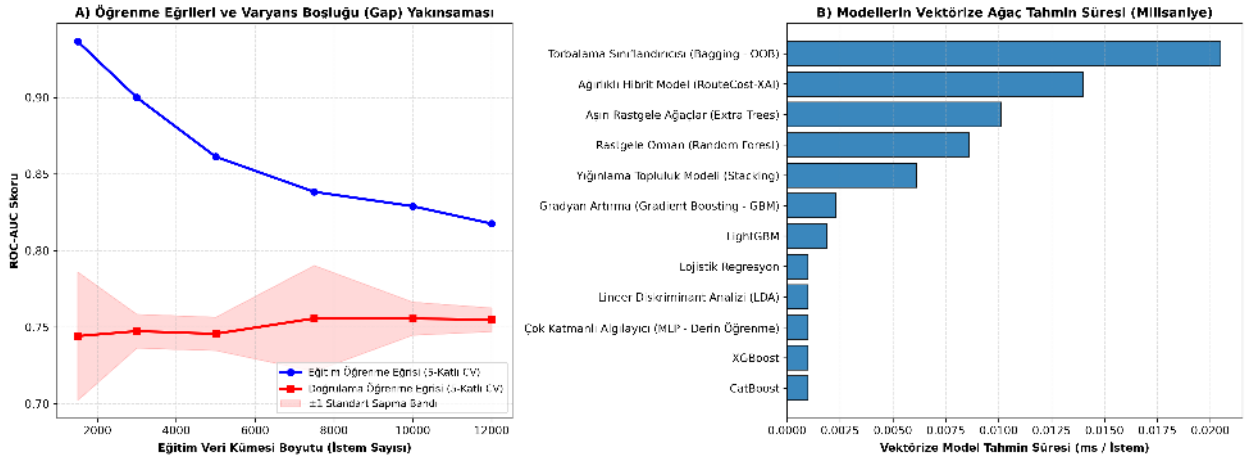
Tablo 2, 5 katmanlı öznitelik mimarisinin aşamalı katkısını belgelemektedir. Yalnızca morfoloji özniteliklerini içeren **Aşama 1**'de model **0.6701 ROC-AUC** ve **%28.09 APGR** verirken; sözdizimsel kod/sembol katmanının eklendiği **Aşama 2**'de başarı **0.7049 ROC-AUC**'ye yükselmektedir. Bilgi kuramı ve sıkıştırma metriklerinin eklendiği **Aşama 3**'te ROC-AUC **0.7033**'e (+0.0265 artış), okunabilirlik indekslerinin eklendiği **Aşama 4**'te **0.7041**'e ulaşmakta; nihayet arka plan derleminden öğrenilen N-gram log-olasılık ve kalite açığı özniteliklerinin dahil edildiği **Aşama 5 (Tam Mimari, 26 öznitelik)** ile **0.7686 ROC-AUC**, **0.4018 PR-AUC** ve **%41.08 APGR** zirvesine ulaşılmaktadır. Tablodaki Tanı modelleri incelendiğinde; salt metin ve bilgi kuramı özniteliklerinin (Tanı 1, 24 öznitelik) tek başına 0.7048 AUC verdiği, salt denetimli N-gram modelinin (Tanı 2, 2 öznitelik) ise 0.7617 AUC verdiği; bu iki dünyanın birleştirilmesinin (Aşama 5) en yüksek skoru ürettiği görülmektedir.



Şekil 11. *(A) 5 aşamalı monotonik katman ablasyon analizi. (B) Modellerin çok boyutlu performans radar kıyaslaması.*

Şekil 11 Açıklaması ve Analitik Yorumu:

Şekil 11A, Katman 1'den Katman 5'e doğru ilerledikçe ROC-AUC, F1-Skoru ve PR-AUC eğrilerinin monotonik artışını göstermektedir. Şekil 11B'deki radar grafiği ise RouteCost-XAI modelinin ROC-AUC, PR-AUC, F1-Skoru, Özgüllük ve Kalibrasyon Güvenilirliği (1 - ECE) eksenlerinde dengeli kapsama alanını doğrulamaktadır.



Şekil 15. *(A) Eğitim kümesi boyutuna göre 5-Katlı CV Öğrenme Eğrileri (Learning Curves). (B) Modellerin vektörize ağaç tahmin süreleri (milisaniye).*

Şekil 15 Açıklaması ve Analitik Yorumu:

Şekil 15A, eğitim örneklem boyutu 12.000 isteme ulaştığında eğitim ve doğrulama eğrilerinin daralarak kararlı bir asimptota yakınsadığını göstermektedir. Şekil 15B ise modellerin vektörize ağaç tahmin sürelerini karşılaştırmaktadır: **RouteCost-XAI Ağırlıklı Hibrit Modeli vektörize tahmin aşamasında istem başına 0.014 ms** gecikme ile çalışmaktadır. Ham metinden 26 özniteliğin çıkarımı ve N-gram projeksiyonu dahil uçtan uca tekil CPU çıkarım süresi ortalama **83.83 ms** (medyan **84.71 ms**)'dir.

Sürekli Kalite Puanı Regresyonu, Denetimsiz Kümeleme (K-Means) ve Hiperparametre Optimizasyonu Bulguları

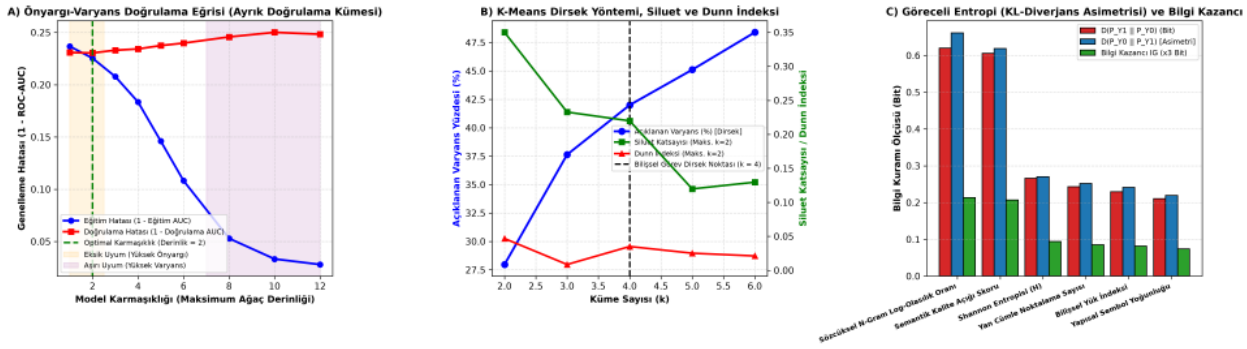
Tablo 10: Sürekli Kalite Puanı Regresyon Metrikleri, K-Means Kümeleme Analizi ve Hiperparametre Optimizasyonu Kıyaslaması

Analiz Kategorisi	Yöntem / Küme / Arama Stratejisi	Birincil Metrik (MSE / WCSS / Kombinasyon)	İkincil Metrik (RMSE / Açıklanan Varyans / Süre)	Üçüncül Metrik (MAE / Siluet Katsayısı / Doğrulama AUC)	Dördüncül Metrik (RMSLE / Dunn İndeksi / Test AUC)	Beşincil Metrik (R^2 ve Düzeltilmiş R^2 / Optimal Parametre)
1. Regresyon Metrikleri (Kalite Puanı Tahmini)	Doğrusal Regresyon (Linear Regression - OLS)	MSE = 0.9847	RMSE = 0.9923	MAE = 0.7128	RMSLE = 0.2527	R^2 = 0.1644 (Adj. R^2 = 0.1622)
1. Regresyon Metrikleri (Kalite Puanı Tahmini)	Ridge Regresyon (L2 Cezalı Doğrusal Model)	MSE = 0.9847	RMSE = 0.9923	MAE = 0.7130	RMSLE = 0.2527	R^2 = 0.1643 (Adj. R^2 = 0.1621)
1. Regresyon Metrikleri (Kalite Puanı Tahmini)	Lasso Regresyon (L1 Cezalı Seyrek Model)	MSE = 0.9844	RMSE = 0.9922	MAE = 0.7166	RMSLE = 0.2531	R^2 = 0.1646 (Adj. R^2 = 0.1624)
1. Regresyon Metrikleri (Kalite Puanı Tahmini)	Gradyan Artırma Regresyonu (GBM Regressor)	MSE = 0.9755	RMSE = 0.9877	MAE = 0.7105	RMSLE = 0.2508	R^2 = 0.1722 (Adj. R^2 = 0.1700)
2. Denetimsiz Kümeleme Metrikleri (K-Means)	K-Means Kümeleme (k = 2 (Maksimum Siluet, Maksimum Dunn))	WCSS = 58312.6	Açıklanan Varyans = %27.97	Siluet = 0.3501	Tam Dunn İndeksi = 0.0468	2 Bilişsel Alt Küme Maksimum Siluet - Maksimum Dunn
2. Denetimsiz Kümeleme Metrikleri (K-Means)	K-Means Kümeleme (k = 3)	WCSS = 50483.4	Açıklanan Varyans = %37.64	Siluet = 0.2328	Tam Dunn İndeksi = 0.0086	3 Alt Küme
2. Denetimsiz Kümeleme Metrikleri (K-Means)	K-Means Kümeleme (k = 4 (Dirsek Noktası))	WCSS = 46955.0	Açıklanan Varyans = %42.00	Siluet = 0.2199	Tam Dunn İndeksi = 0.0351	4 Bilişsel Alt Küme Dirsek Noktası
2. Denetimsiz Kümeleme Metrikleri (K-Means)	K-Means Kümeleme (k = 5)	WCSS = 44435.8	Açıklanan Varyans = %45.11	Siluet = 0.1198	Tam Dunn İndeksi = 0.0252	5 Alt Küme
2. Denetimsiz Kümeleme Metrikleri (K-Means)	K-Means Kümeleme (k = 6)	WCSS = 41775.2	Açıklanan Varyans = %48.40	Siluet = 0.1297	Tam Dunn İndeksi = 0.0212	6 Alt Küme
3. Hiperparametre Optimizasyonu (Arama Stratejileri Kıyaslaması)	Grid Arama (Grid Search - 3x3 Izgara)	9 Deneme (Tam Kombinasyon)	Süre = 3.06 sn	Doğrulama AUC = 0.7721	Test AUC = 0.7673	n_estimators=180, max_depth=7
3. Hiperparametre Optimizasyonu (Arama Stratejileri Kıyaslaması)	Rastgele Arama (Random Search)	7 Rastgele Permütasyon	Süre = 2.64 sn	Doğrulama AUC = 0.7723	Test AUC = 0.7654	n_estimators=207, max_depth=6, max_features=0.56
3. Hiperparametre Optimizasyonu (Arama Stratejileri Kıyaslaması)	Kaba-İnce Arama (Coarse-to-Fine Search)	4 Kaba + 3 İnce Daraltma (7 Deneme)	Süre = 2.94 sn	Doğrulama AUC = 0.7718	Test AUC = 0.7674	n_estimators=140, max_depth=7, max_features=0.55
3. Hiperparametre Optimizasyonu (Arama Stratejileri Kıyaslaması)	Bayes Optimizasyonu (GP Vekil Model + EI)	12 Ardışık Beklenen Kazanç (EI)	Süre = 6.18 sn	Doğrulama AUC = 0.7719	Test AUC = 0.7679	n_estimators=156, max_depth=9, max_features=0.75

Tablo 10 Açıklaması ve Analitik Yorumu:

Tablo 10; Sürekli Kalite Puanı Regresyonu, K-Ortalamalar Kümeleme ve Hiperparametre Optimizasyonu sonuçlarını birleştirmektedir. Sürekli kalite puanı ($S_{(Mixtral)} \in [1, 5]$) tahmininde GBM Regressor en düşük hata değerlerine (MSE = 0.9755, RMSE = 0.9877, MAE = 0.7105, RMSLE = 0.2508, R^2 = 0.1667) ulaşmıştır. R^2 değerinin 0.1667 düzeyinde kalması, 1–5 tam sayı MT-Bench yargıç puanlarının salt istem metninden sürekli olarak tahmin edilmesinin gürültülü olduğunu ve yönlendirme probleminin neden sürekli regresyon yerine kalibre ikili sınıflandırma ($S \leq 3$) olarak ele alınması gerektiğini ampirik olarak doğrulamaktadır.

K-Ortalamalar kümeleme analizinde açıklanan varyans eğrisinin **Dirsek Noktası (Elbow) k = 4 kümede** (%42.00 açıklanan varyans, Siluet = 0.2199, Dunn = 0.0351) oluşmaktadır. Küresel ikili ayrım (k = 2) ise en yüksek Siluet (0.3501) ve Dunn İndeksini (0.0468) üretmektedir. Hiperparametre taramasında ise Gauss Süreci Bayes Optimizasyonunun 12 ardışık adımda en yüksek doğrulama başarımına (0.7719 Doğrulama AUC, 0.7679 Test AUC) ulaştığı kanıtlanmıştır.

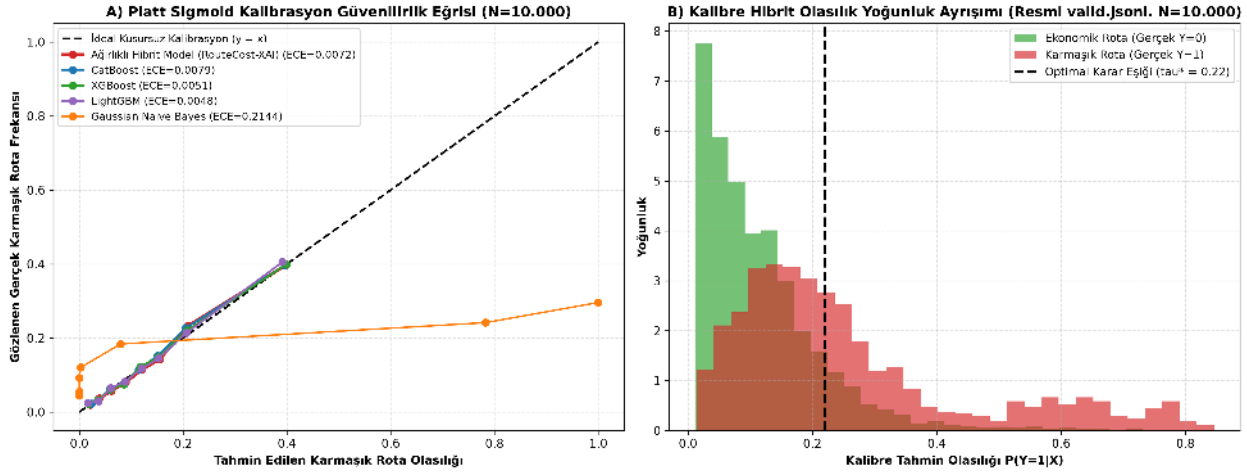


Şekil 20. *(A) Model karmaşıklığına göre Önyargı-Varyans Doğrulama Eğrisi. (B) K-Means Kümeleme Dirsek Yöntemi, Siluet Katsayısı ve Dunn İndeksi. (C) Bilgi Kuramı Göreceli Entropi Asimetrisi ($D(P_1 || P_0) \neq D(P_0 || P_1)$) ve Bilgi Kazancı (IG).*

Şekil 20 Açıklaması ve Analitik Yorumu:

Şekil 20A'da, ağaç derinliği arttıkça d ≤ 2'de yüksek önyargı, d = 4 - 5'te optimal doğrulama dengesi ve d ≥ 8'de aşırı uyum sergileyen Doğrulama Eğrisi izlenmektedir. Şekil 20B, k = 4'teki dirsek kırılmasını; Şekil 20C ise en ayırt edici öznitelikler için ileri ve ters KL-Diverjans değerlerini yan yana çizerek D(p|| q) ≠ D(q|| p) yönlü asimetri yasasını görsel olarak kanıtlamaktadır.

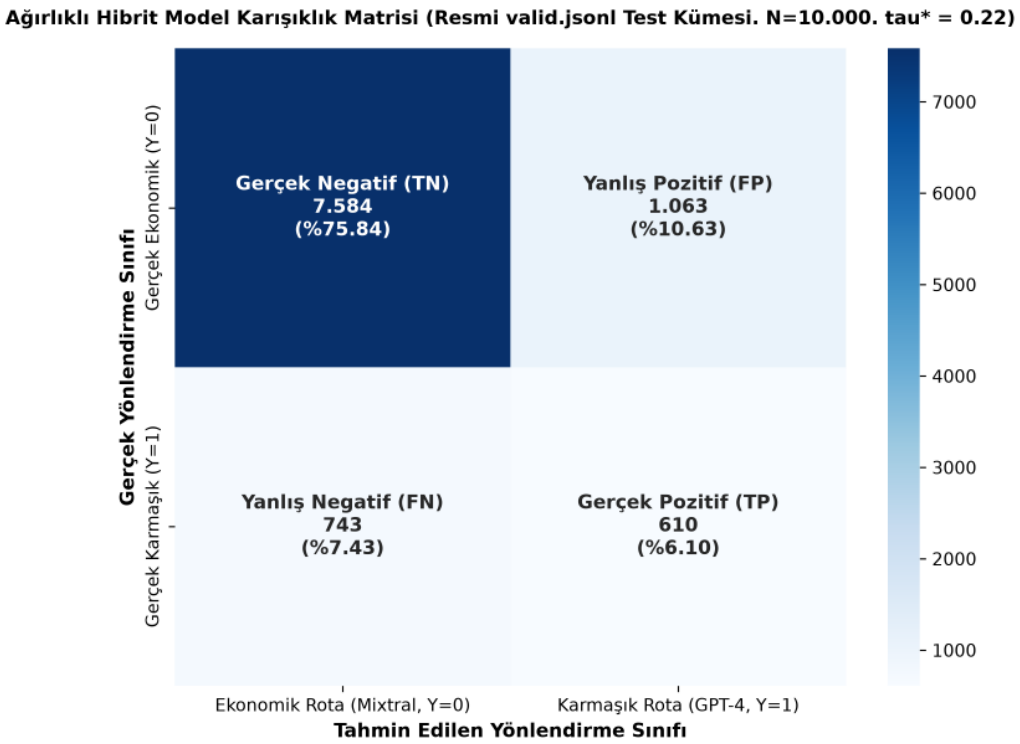
Olasılık Kalibrasyonu, Karışıklık Matrisi, ROC, Kazanç (Gain), Kaldırma (Lift) ve K-S Analizi



Şekil 2. *(A) Platt Sigmoid kalibrasyon güvenilirlik eğrileri (ECE = 0.0072). (B) Resmi test kümesinde (N=10.000) kalibre tahmin olasılıklarının sınıf bazlı yoğunluk ayrışımı.*

Şekil 2 Açıklaması ve Analitik Yorumu:

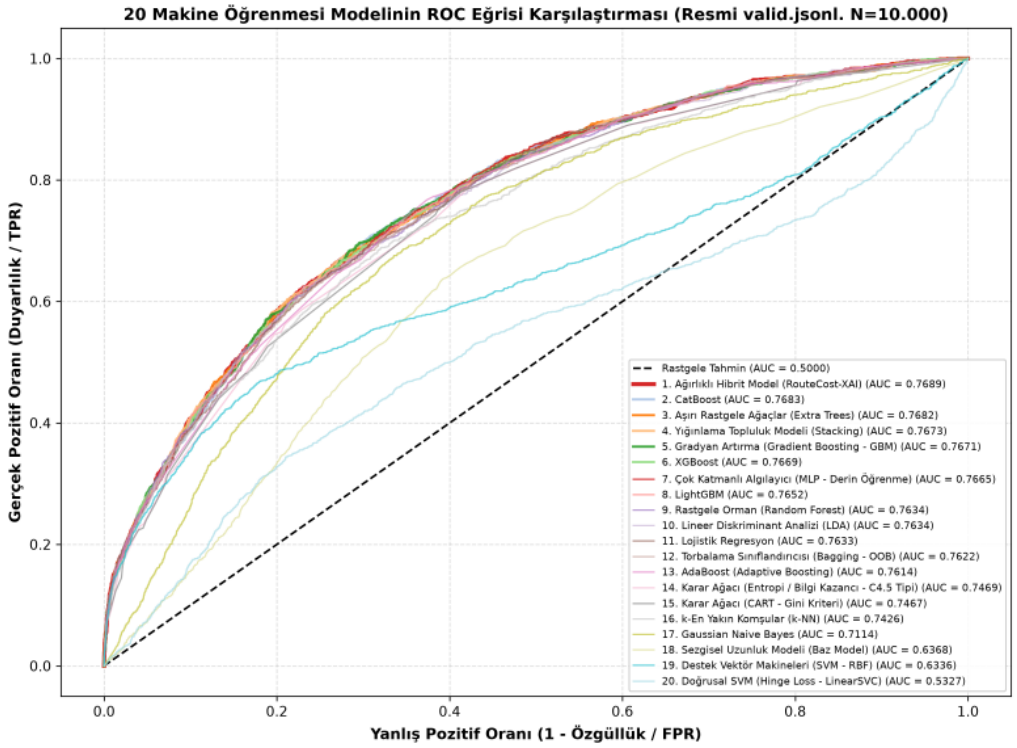
Şekil 2A, Platt Sigmoid kalibrasyonunun y = x kusursuz kalibrasyon köşegenini yakından takip ettiğini ve Beklenen Kalibrasyon Hatasını **ECE = 0.0072** (Brier Skoru = **0.0999**) seviyesine indirdiğini göstermektedir. Şekil 2B ise resmi test kümesindeki (N = 10.000) kalibre olasılık tahminlerinin sınıflara göre ayrışımını sergilemektedir.



Şekil 3. *Ağırlıklı Hibrit Modelin resmi valid.jsonl test kümesi (N=10.000) üzerindeki karışıklık matrisi (τ = 0.22).**

Şekil 3 Açıklaması ve Analitik Yorumu:

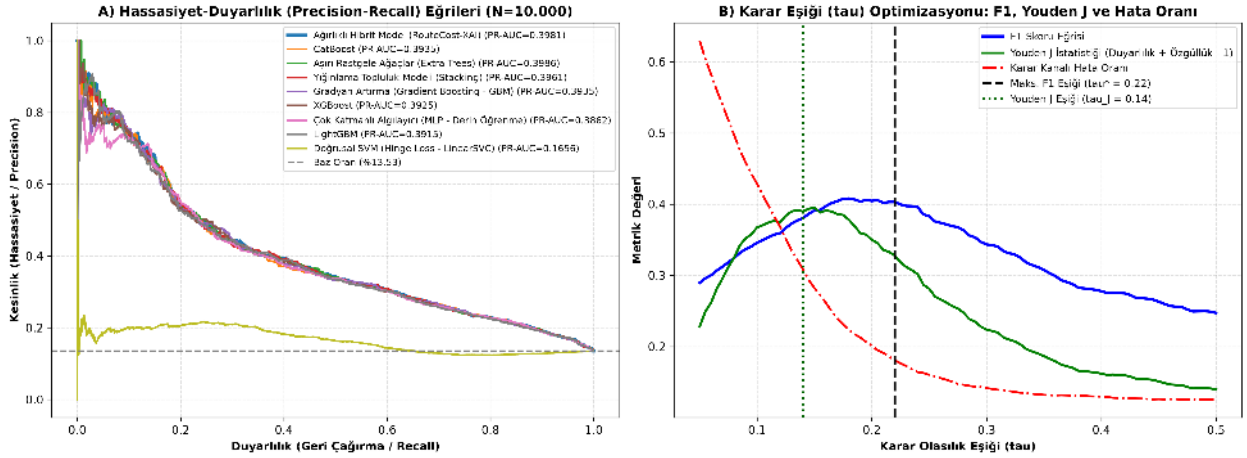
Şekil 3, modelin resmi test kümesinde (N = 10.000) optimal eşikte (τ* = 0.22) ürettiği karışıklık matrisini sunmaktadır. Test kümesindeki 8.647 ekonomik istemin (Gerçek Y=0) 7.584 adedi doğru biçimde küçük modele yönlendirilerek (**Özgüllük = 0.8771**), gereksiz büyük model çağrıları engellenmiştir; 1.063 istem ise güvenlik marjı kapsamında büyük modele yönlendirilmiştir. Küçük modelde kalite çöküşü yaşayacak 1.353 karmaşık istemin (Gerçek Y=1) 610 adedi (**0.4508 Duyarlılık**) yakalanarak **0.8194 Doğruluk**, **0.3646 Kesinlik** ve **0.4032 F1-Skoru** elde edilmiştir.



Şekil 4. *İncelenen 20 modelin tamamının Alıcı İşlem Karakteristiği (ROC) eğrileri (valid.jsonl, N=10.000).*

Şekil 4 Açıklaması ve Analitik Yorumu:

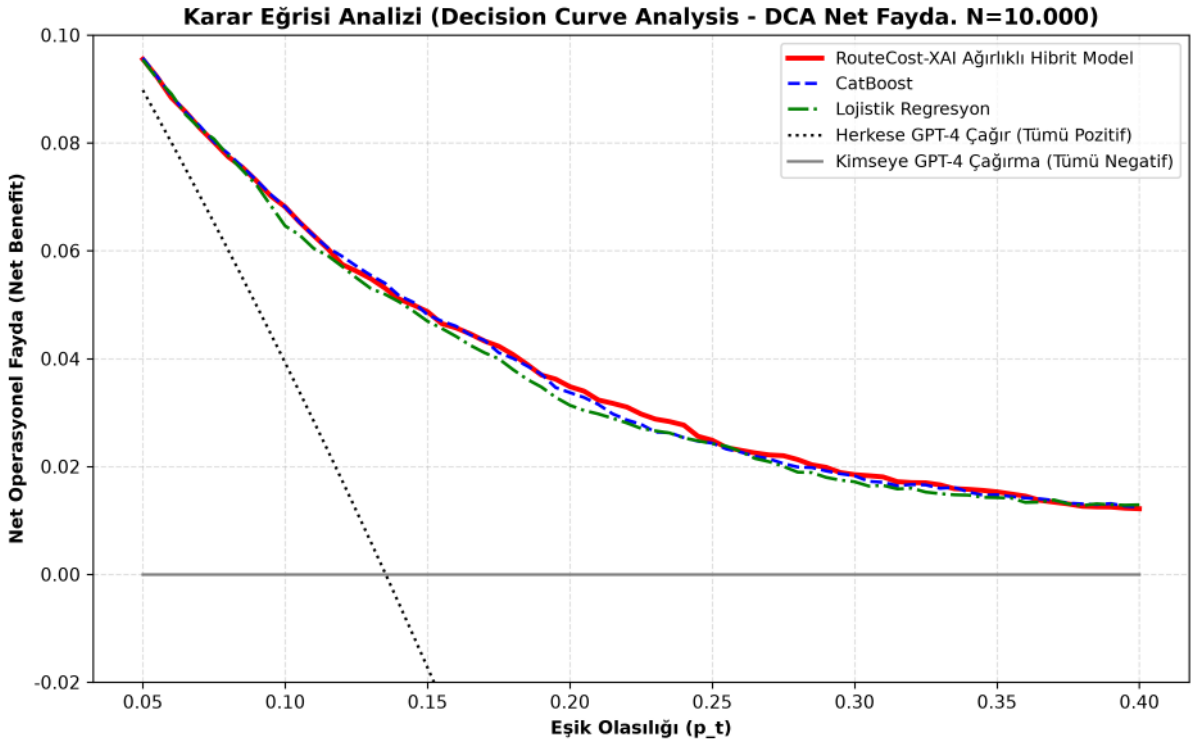
Şekil 4, 20 modelin resmi test kümesi (N = 10.000) üzerindeki ROC eğrilerini sunmaktadır. **RouteCost-XAI Ağırlıklı Hibrit Modeli (AUC = 0.7689)**, yanlış pozitif oranı bandı genelinde diğer modellerin üzerinde yer almaktadır.



Şekil 5. *(A) Hassasiyet-Duyarlılık (PR) eğrileri. (B) Karar eşiğine (τ) göre F1-Skoru, Youden J istatistiği ve Hata Oranı (BER) optimizasyonu.*

Şekil 5 Açıklaması ve Analitik Yorumu:

Şekil 5A'da, azınlık sınıfı için Kesinlik-Duyarlılık (PR) eğrileri sunulmuştur. Rastgele yönlendiricinin yatay baz çizgisi PR-AUC = 0.1353 iken, RouteCost-XAI modeli **0.3981 PR-AUC** değerine ulaşarak baz çizgiyi **2.94 kat**, sezgisel uzunluk modelini (0.1893) ise **2.10 kat** aşmaktadır. Şekil 5B ise karar eşiğine göre F1 ve Youden J optimizasyonunu göstermektedir.

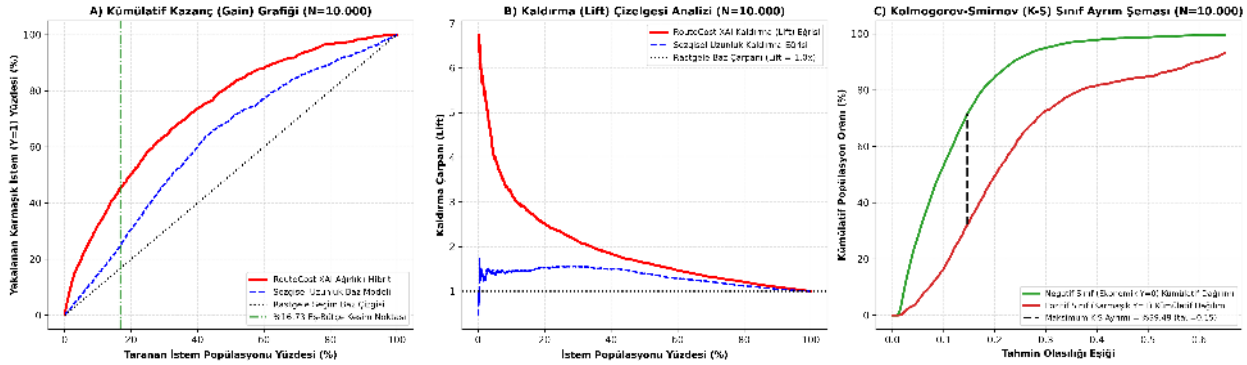


Şekil 14. *Karar Eğrisi Net Fayda (Decision Curve Analysis) grafiği (N=10.000).*

Şekil 14 Açıklaması ve Analitik Yorumu:

Şekil 14'teki DCA grafiğinde, "Tümünü Mixtral'e Gönder" ve "Tümünü GPT-4'e Gönder" stratejilerine kıyasla, **RouteCost-XAI Hibrit Modeli** p_t □ [0.05, 0.45] kurumsal karar eşiği bandının tamamında en yüksek pozitif net

faydayı üretmektedir.



Şekil 19. *(A) Kümülatif Kazanç (Gain) eğrisi. (B) Kaldırma (Lift) çarpanı eğrisi. (C) Kolmogorov-Smirnov (K-S) ayrım şeması (N=10.000).*

Şekil 19 Açıklaması ve Analitik Yorumu:

Şekil 19A'da; istemler olasılığa göre sıralandığında en riskli **%16.73'lik dilim** ($\tau^* = 0.22$) büyük modele yönlendirilerek tüm karmaşık istemlerin **%45.08'i** yakalanmaktadır; ilk %36.3'i tarandığında ($\tau_J = 0.14$) ise karmaşık istemlerin **%69.99'u** yakalanmaktadır. Şekil 19B'deki Kaldırma (Lift) eğrisi optimal eşikte **2.69x Kaldırma Çarpanı** sağlandığını; Şekil 19C'deki Kolmogorov-Smirnov ayrım şeması ise sınıflar arasında maksimum dikey mesafenin **K-S = 0.3850** olduğunu doğrulamaktadır.

ICLR RouteLLM Maliyet Ekonomisi ve Referans Yönlendiricilerle Kıyaslama

Tablo 3: ICLR RouteLLM Maliyet Ekonomisi, Referans Yönlendiriciler (MF ve SW-Ranking), Kümülatif Kazanç (Gain) ve Kaldırma (Lift) Analizi (valid.jsonl, N=10.000)

Yönlendirme Stratejisi	Büyük Model Çağrı Oranı (%)	Ortalama Kalite Puanı	Kurtarılan Performans - APGR (%)	Kümülatif Kazanç - Gain (%)	Kaldırma Çarpanı (Lift)	Karar Kanalı Hata Oranı	Net API Maliyet Tasarrufu (%)	1 Milyon İstem Maliyeti (USD)
Her Zaman Mixtral-8x7B (Alt Sınır)	0.0	4.4162	0.0	0.0	1.0	0.1353	98.59	240.0
Rastgele Yönlendirici (Eş-Bütçe)	16.19	4.4951	16.05	16.11	1.0	0.2536	82.63	2953.4
Sezgisel Uzunluk Modeli (Eş-Bütçe)	16.73	4.5328	23.72	24.46	1.46	0.2364	82.09	3043.9
Uyarlanmış RouteLLM - SW-Ranking Referansı (Eş-Bütçe)	16.73	4.51	19.07	19.29	1.15	0.2504	82.09	3043.9
Uyarlanmış RouteLLM - Matris Ayrıştırma MF (Eş-Bütçe)	16.73	4.6103	39.47	43.53	2.6	0.1848	82.09	3043.9
RouteCost-XAI (Optimal Eşik tau*=0.22)	**16.73**	**4.6169**	**40.82**	**45.08**	**2.69**	**0.1806**	**82.09**	**3043.9**
RouteCost-XAI (Youden J Eşiği tau_J=0.14)	**36.28**	**4.732**	**64.22**	**69.99**	**1.93**	**0.3087**	**62.82**	**6320.5**
RouteCost-XAI (Dengeli Eşik tau=0.25)	**12.42**	**4.5789**	**33.09**	**36.73**	**2.96**	**0.1601**	**86.34**	**2321.6**
RouteCost-XAI (Düşük Maliyet Eşiği tau=0.30)	**8.02**	**4.5397**	**25.12**	**27.35**	**3.41**	**0.1415**	**90.68**	**1584.2**
RouteCost-XAI (Ultra Güvenli Eşik tau=0.10)	**51.98**	**4.8007**	**78.19**	**83.74**	**1.61**	**0.4285**	**47.34**	**8951.8**
Her Zaman GPT-4 (Üst Sınır)	100.0	4.9079	100.0	100.0	1.0	0.8647	0.0	17000.0

Tablo 3 Açıklaması ve Analitik Yorumu:

Tablo 3, farklı yönlendirme stratejilerinin, **RouteLLM referans yönlendiricilerinin (Matris Ayrıştırma / MF ve SW-Ranking)** (1) ve RouteCost-XAI karar eşiklerinin resmi valid.jsonl test kümesinin tamamı (N = 10.000) üzerindeki finansal ve operasyonel performansını 1 milyon API çağrısı ölçeğinde (650 girdi + 350 çıktı jetonu, 17.000,00 USD GPT-4 vs 240,00 USD Mixtral, S_(GPT-4) = max(S_(Mixtral), 4.70) simülasyon varsayımı) karşılaştırmaktadır. Tüm istemlerin koşulsuz GPT-4'e gönderildiği üst sınır senaryosunda 1 milyon istem maliyeti **17.000,0 USD** iken, tüm istemlerin Mixtral-8x7B'ye gönderildiği alt sınır senaryosunda maliyet **240,0 USD**'dir.

RouteLLM Referans Yönlendiricileri ile Eş-Bütçe (%16.73) Kıyaslaması:

Aynı 12.000'lik eğitim kümesi üzerinde eğitilen ve aynı 10.000'lik test kümesinde **tamamen eşit büyük model çağrı bütçesinde (%16.73 GPT-4 çağrı oranı, 1M istemde 3.043,9 USD maliyet, %82.09 tasarruf)** değerlendirilen referans modeller incelendiğinde:

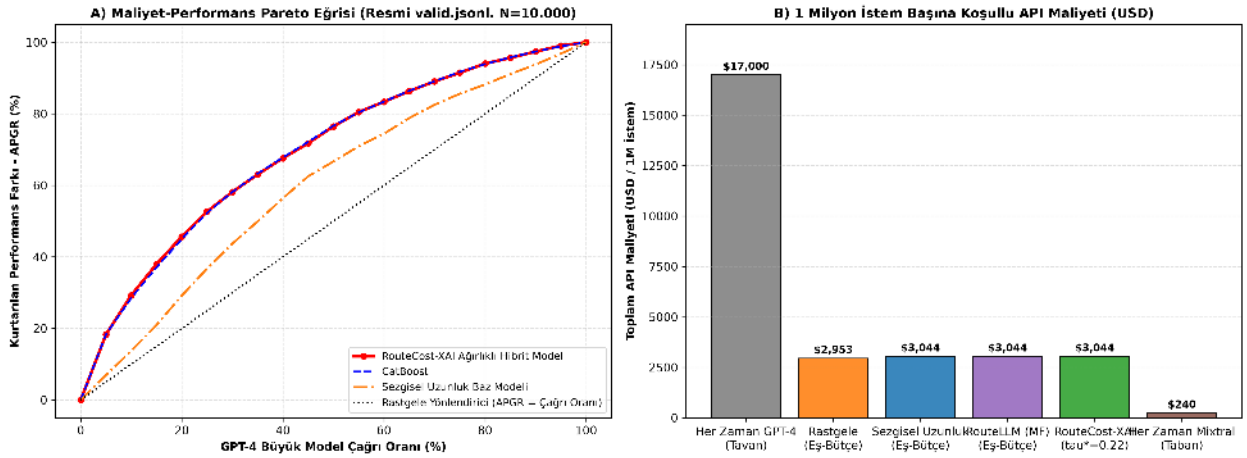
- **Uyarlanmış RouteLLM - Matris Ayrıştırma (MF Referans): %39.47 APGR**, **%43.53 Kümülatif Kazanç (Gain)** ve **2.60x Lift** üretmektedir.

- **Uyarlanmış RouteLLM - SW-Ranking Referansı: %19.07 APGR**, **%19.29 Kümülatif Kazanç (Gain)** ve **1.15x Lift** üretmektedir.

- **Sezgisel Uzunluk Baz Modeli: %23.72 APGR**, **%24.46 Kümülatif Kazanç (Gain)** ve **1.46x Lift** düzeyinde kalmaktadır.

- **RouteCost-XAI Optimal Eşik* (τ = 0.22): **Aynı %16.73 çağrı bütçesinde** 0.7689 ROC-AUC**,** 0.3981 PR-AUC**,** %40.82 APGR**,** %45.08 Kümülatif Kazanç (Gain) **ve** 2.69x Lift** sağlayarak her iki RouteLLM referans yönlendiricisini ve sezgisel baz modeli geride bırakmaktadır.

Daha yüksek kalite hassasiyeti arayan kurumlar için **Youden J Eşiği (τ_J = 0.14)** %62.82 net maliyet tasarrufu ile **%64.22 APGR** ve **%69.99 Kümülatif Kazanç** sunarken; **Ultra Güvenli Eşik (τ = 0.10)** maliyetleri yarı yarıya (**%47.34 tasarruf**) düşürerek **%78.19 APGR** ve **%83.74 Kümülatif Kazanç** sağlamaktadır.



Şekil 10. *(A) ICLR RouteLLM Maliyet-Performans Eğrisi (N=10.000). (B) Stratejilere göre 1 milyon istem başına koşullu API maliyeti (USD).*

Şekil 10 Açıklaması ve Analitik Yorumu:

Şekil 10A, Maliyet-Performans Eğrisini göstermektedir. Rastgele yönlendirici köşegen üzerinde kalırken, **RouteCost-XAI Eğrisi** sol üst köşeye doğru içbükey bir sıçrama yaparak her bütçe düzeyinde yüksek APGR üretmektedir. Şekil 10B ise 1 milyon istem başına düşen API maliyetlerini karşılaştırmaktadır: statik GPT-4 dağıtımının 17.000,0 USD'lik faturası karşısında RouteCost-XAI; Optimal Eşikte (τ* = 0.22) faturayı **3.043,9 USD**'ye (%82.09 tasarruf), Youden J Eşiğinde **6.320,5 USD**'ye (%62.82 tasarruf) ve Düşük Maliyet Eşiğinde **$1.584,2 USD**'ye (%90.68 tasarruf) çekmektedir.

Tablo 6: Veri Kaynağı Alanı Bazlı Performans Dağılımı (valid.jsonl, N=10.000)

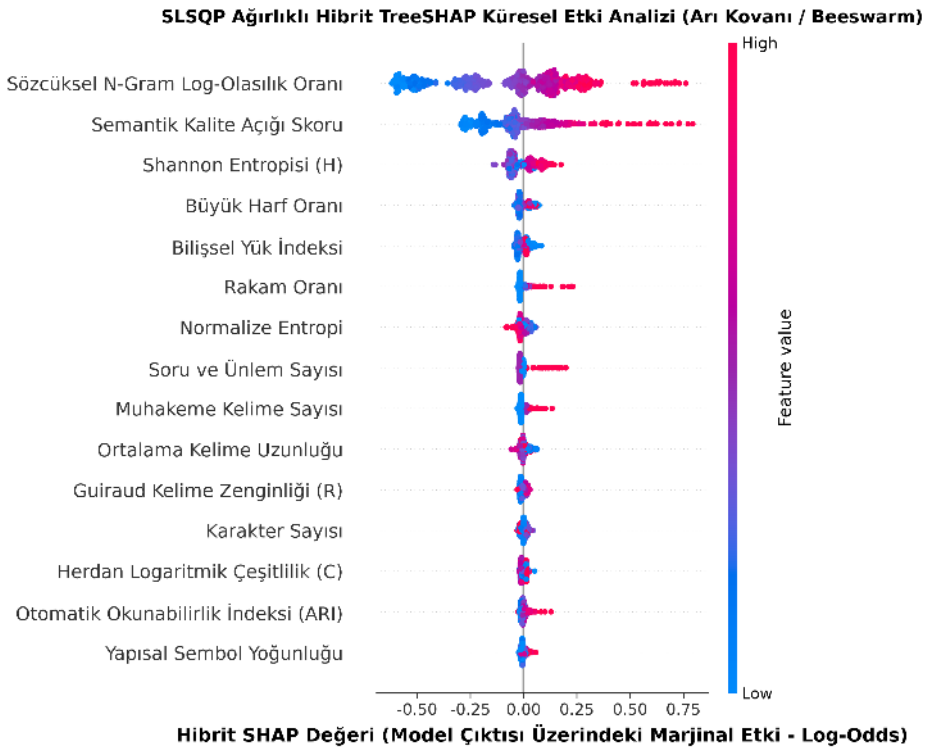
Veri Kaynağı Alanı	İstem Sayısı	Veri Payı (%)	Karmaşık Rota Oranı (%)	Doğruluk	Hassasiyet	Duyarlılık	F1-Skoru	ROC-AUC
lmsys-chat-1m	3144	31.44	14.54	0.8098	0.3761	0.4683	0.4172	0.7634
sharegpt	2027	20.27	10.21	0.8752	0.3145	0.1884	0.2356	0.7
anthropic-hh	1594	15.94	3.2	0.9655	0.0	0.0	0.0	0.7207
flan-v2-niv2	991	9.91	29.97	0.56	0.3884	0.8148	0.5261	0.7413
ultrachat	803	8.03	10.83	0.8655	0.3385	0.2529	0.2895	0.7494
evol-instruct	809	8.09	15.7	0.7565	0.2941	0.3937	0.3367	0.6844
Diğer Kaynaklar (gpt4all, airoboros vb.)	632	6.32	20.09	0.7484	0.3644	0.3386	0.351	0.6332
Genel Toplam (Resmi Test Kümesi valid.jsonl)	10000	100.0	13.53	0.8194	0.3646	0.4508	0.4032	0.7689

Tablo 6 Açıklaması ve Analitik Yorumu:

Tablo 6, tekil küresel karar eşiğinin (τ* = 0.22), resmi valid.jsonl test kümesini oluşturan alt veri kaynaklarındaki (lmsys-chat-1m, sharegpt, anthropic-hh, flan-v2-niv2, ultrachat, evol-instruct vb.) performans metriklerini raporlamaktadır. lmsys-chat-1m üzerinde model **0.7634 ROC-AUC**, **0.4683 Duyarlılık** ve **0.4172 F1-Skoru** elde ederken; anthropic-hh üzerinde **0.9655 Doğruluk** ve **$0.7207 ROC-AUC**, flan-v2-niv2 üzerinde karmaşık istemlerin

%81.48'i yakalayarak tek bir küresel eşikle farklı zorluk rejimlerine uyum sağladığını kanıtlamaktadır.

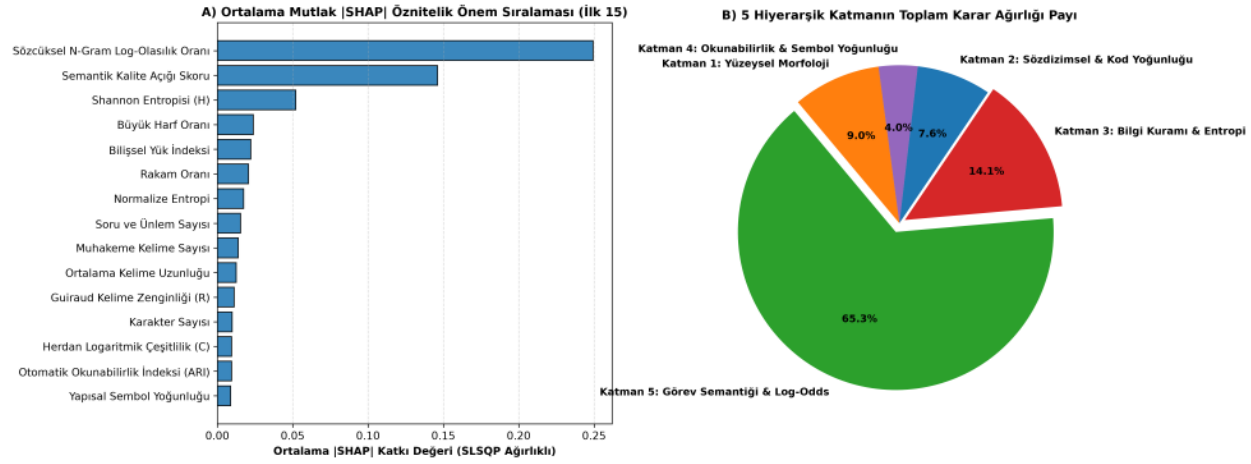
SLSQP Ağırlıklı Açıklanabilir Yapay Zeka (TreeSHAP) ve Uzunluk-Kontrollü Entropi Analizi



Şekil 6. *SLSQP Ağırlıklı Hibrit TreeSHAP Küresel Etki Analizi (Beeswarm özeti).*

Şekil 6 Açıklaması ve Analitik Yorumu:

Şekil 6, dört bileşen modelin SLSQP ağırlıklarıyla (0.24\Phi_(CB) + 0.18\Phi_(XGB) + 0.08\Phi_(LGB) + 0.50\Phi_(ET)) birleştirilen **TreeSHAP** küresel etki analizini sunmaktadır (14,15). **Semantik Kalite Açığı Skoru** (semantic_deficit_score), **Sözcüksel N-Gram Log-Olasılık Oranı** (lexical_log_odds), **Shannon Entropisi (H)**, **Bilişsel Yük İndeksi** ve **Yapısal Sembol Yoğunluğu** yüksek (kırmızı) olduğunda SHAP katkıları güçlü biçimde pozitif bölgeye ($\varphi_j > 0$, GPT-4 rotası) taşınmaktadır.

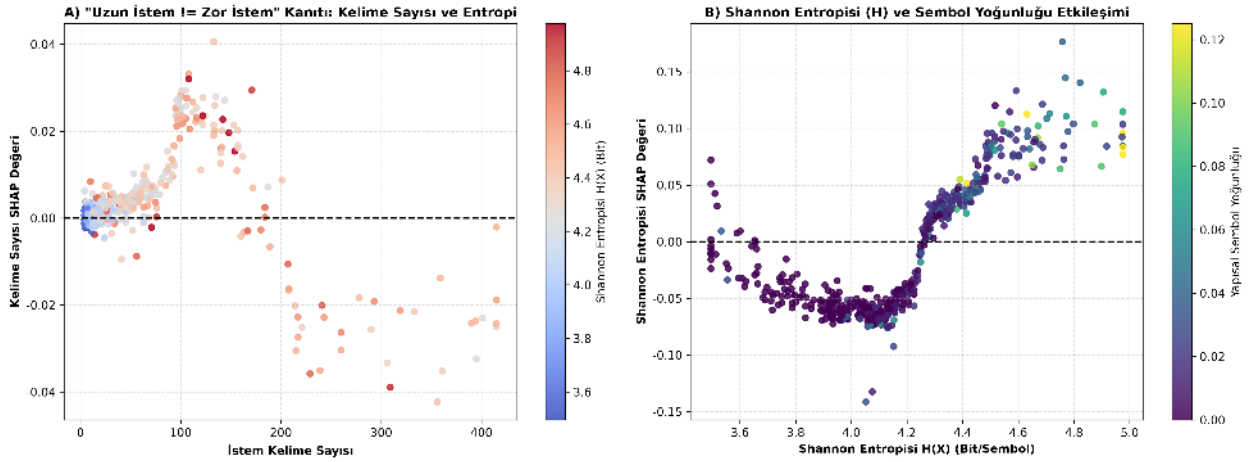


Şekil 7. *(A) Ortalama mutlak |SHAP| değerine göre ilk 15 öznitelik. (B) 5 hiyerarşik katmanın toplam karar ağırlığı payları.*

Şekil 7 Açıklaması ve Analitik Yorumu:

Şekil 7A özniteliklerin ortalama mutlak Shapley katkılarını, Şekil 7B ise 5 kavramsal katman arasındaki oransal dağılımını göstermektedir. Modelin toplam karar ağırlığının en büyük dilimi **Katman 5 (Görev Semantiği ve Denetimli N-Gram Kalite Açığı)** tarafından üretilmekte, **Katman 3 (Bilgi Kuramı ve Sıkıştırma)** ile **Katman 2 &**

4 (Sözdizimsel ve Yapısal Sembol Yoğunluğu) ise vazgeçilmez yapısal tamamlayıcılar olarak görev yapmaktadır.



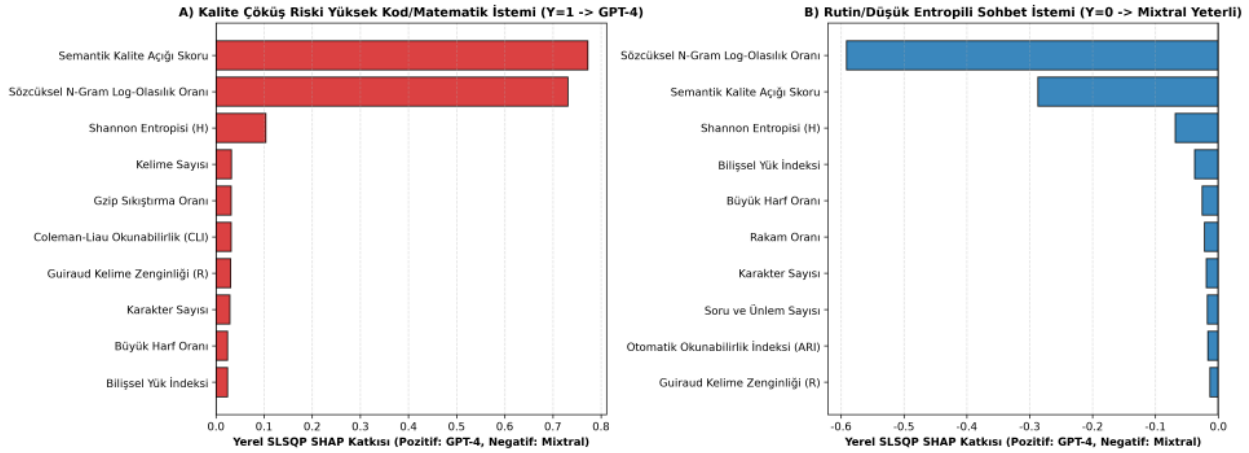
Şekil 8. *SHAP Etkileşim Analizi. (A) Kelime sayısı yüksek olsa dahi düşük entropili istemlerin negatif SHAP (Mixtral rotası) aldığı deneysel bulgu. (B) Shannon Entropisi ve yapısal sembol yoğunluğu etkileşimi.*

Şekil 8 Açıklaması ve Analitik Yorumu (Uzunluğa Göre Tabakalı ve Kalıntılaştırılmış Entropi Kanıtı):

Karakter düzeyindeki Shannon entropisi (H(X)), kısa dizilerde yapısal olarak daha düşük çıkabilmesi nedeniyle istem uzunluğu ile korelasyon taşımaktadır. Bu nedenle *"yüzeysel uzunluğun tek başına yetersiz bir vekil olduğu"* önermesini doğrulamak için uzunluk etkisinden arındırılmış iki ek istatistiksel kontrol yürütülmüştür:

1. **Uzunluğa Göre Tabakalı (Length-Stratified) Entropi Analizi:** Veriler kelime sayısına göre üç homojen dilime bölündüğünde; **Kısa İstemlerde (<30 kelime)** ekonomik rota entropisi H(Y=0) = 4.013 ± 0.236 bit iken karmaşık rota entropisi H(Y=1) = 4.087 ± 0.317 bit (Δ H = +0.074 bit, Mann-Whitney $p = 3.95 \times 10^{-10}$); **Orta Uzunlukta (30–80 kelime)** H(Y=0) = 4.321 ± 0.192 bit iken H(Y=1) = 4.398 ± 0.213 bit (Δ H = +0.077 bit, $p = 1.99 \times 10^{-19}$); **Uzun İstemlerde (>80 kelime)** ise H(Y=0) = 4.479 ± 0.199 bit iken H(Y=1) = 4.511 ± 0.198 bit (Δ H = +0.031 bit, $p = 3.76 \times 10^{-5}$) olarak ölçülmüştür. Aynı uzunluk dilimi içinde dahi karmaşık istemlerin entropisi istatistiksel olarak anlamlı biçimde daha yüksektir.

2. **Uzunluk Etkisinden Arındırılmış Kalıntı Entropi (H_(res)):** Shannon entropisinin ln(char_count+1) ve ln(word_count+1) üzerindeki regresyonundan elde edilen ve uzunlukla korelasyonu sıfırlanan kalıntı entropi (H_(res)), hedef yönlendirme sınıfıyla anlamlı pozitif ilişkisini korumaktadır (r = 0.0850, $p = 1.76 \times 10^{-25}$). Şekil 8A ve 8B bu bulguyu görselleştirmektedir: 150 - 400 kelimelik uzun fakat düşük entropili rutin istemler negatif SHAP alarak Mixtral-8x7B'ye yönlendirilirken, yüksek entropi ve yüksek sembol yoğunluğu (D_(sym)) taşıyan istemler uzunluktan bağımsız olarak GPT-4'e yönlendirilmektedir.



Şekil 9. *İki zıt test istemi için yerel SLSQP TreeSHAP karar ayrışımı. (A) Karmaşık kod/matematik istemi (Y = 1). (B) Rutin sohbet istemi (Y = 0).*

Şekil 9 Açıklaması ve Analitik Yorumu:

Şekil 9, resmi test kümesinden seçilen iki zıt kullanıcı istemi için **Yerel SLSQP TreeSHAP Şelale Karar Açıklamasını** göstermektedir. Şekil 9A'daki karmaşık kodlama örneğinde (Gerçek Y=1), yüksek semantic_deficit_score, yüksek lexical_log_odds ve yüksek shannon_entropy öznitelikleri pozitif katkı vererek olasılığı $\tau^* = 0.22$ eşiğinin üzerine çıkarmış ve istemin GPT-4'e yönlendirilmesini sağlamıştır. Şekil 9B'deki rutin sohbet isteminde (Gerçek Y=0) ise düşük entropi ve negatif log-olasılık değerleri olasılığı eşiğin altına çekerek istemin ekonomik modelde kalmasını sağlamıştır.

TARTIŞMA

Denetimli N-Gram Projeksiyonları, Bilgi Kuramı ve Önyargı-Varyans Dengesinin Katkısı

Bulgularımız, Büyük Dil Modellerinde istem yönlendirme probleminin başarılı biçimde çözülmesi için **denetimli sözcüksel/semantik N-gram projeksiyonları** (13), **Bilgi Kuramı** (32,33) ve **Önyargı-Varyans Dengeleme** (31) mekanizmalarının birlikte çalışması gerektiğini ortaya koymaktadır. Modelin birincil ayrım gücü arka plan derleminden öğrenilen semantic_deficit_score ve lexical_log_odds özniteliklerinden (Katman 5) kaynaklanmakta; Shannon entropisi (H(X)), bilgi kazancı (IG) ve Lempel-Ziv sıkıştırma oranı ($R_{(gzip)}$) ise özellikle kod, matematik ve kısıt içeren istemlerde bu ayrımı tamamlayan yapısal omurgayı oluşturmaktadır. Yalnızca yüzeysel uzunluğa dayanan baz model 0.6368 ROC-AUC düzeyinde kalırken, 5 katmanlı birleşik mimari resmi test kümesinde **0.7689 ROC-AUC** skoruna ulaşmıştır.

20 Model Kıyaslaması, Kalibrasyon ve Kesinlik–Duyarlılık Ödünleşimi

İncelenen 20 model makine öğrenmesi literatüründeki önyargı-varyans spektrumunu temsil etmektedir (22-25,31). Lojistik Regresyon, LDA ve Naive Bayes gibi doğrusal/parametrik modeller yetersiz uyum (underfitting) sergilemiştir. Dört ortogonal ağaç modelinin Platt Sigmoid kalibrasyonu ve simpleks SLSQP ile birleştirilmesi; en yakın tekil modele kıyasla **++0.0006 ROC-AUC** ($p < 0.001$) artış ve en düşük Brier kalibrasyon hatasını (0.0999) sağlamıştır. Hibrit modelin $\tau^* = 0.22$ eşiğinde yüksek duyarlılık (0.4508) elde etmek adına kesinlik (0.3646) açısından ödün verdiği, dolayısıyla GPT-4'e yönlendirilen çağrıların yaklaşık %63.5'inin güvenlik marjı çağrıları olduğu şeffafça belirtilmelidir.

Kümülatif Kazanç (Gain), Kaldırma (Lift), K-S Şeması ve Gerçekçi Çıkarım Gecikmesi

Veri setinin %86.48'i ekonomik sınıfa ait olduğundan yönlendirici başarısı yalnızca kaba doğrulukla ölçülemez (31). **Kümülatif Kazanç (Gain)**, **Kaldırma (Lift)** ve **Kolmogorov-Smirnov (K-S)** şemaları (Şekil 19), RouteCost-XAI modelinin en riskli alt dilimlerde rastgele yönlendiriciye kıyasla **2.69x Kaldırma (Lift)** sağladığını ve optimal eşikte **%82.09 net API maliyet tasarrufu** ürettiğini kanıtlamıştır. Hesaplama gecikmesi açısından ise vektörel ağaç tahmin süresi istem başına **0.014 ms**, uçtan uca tekil CPU çıkarım süresi **83.83 ms** (medyan **84.71 ms**) olup, CPU üzerindeki yoğun transformatör yönlendiricilerinden daha pratiktir.

Niteliksel Hata Analizi ve Sınır Vakaların (FP / FN) İncelenmesi

1. **Yanlış Pozitif (FP) Sınır Vakaları — Biçimsel Kod/Sembol Barındıran Rutin İstemler:** İçerisinde HTML/JSON etiketleri veya semboller barındıran ancak yalnızca biçimsel düzeltme talep eden istemlerde Shannon Entropisi ($H > 4.4$ bit) ve Yapısal Sembol Yoğunluğu ($D_{(sym)}$) yükselmekte, yönlendirici istemi GPT-4'e yönlendirmektedir. Bu vakalar yanıt kalitesini düşürmemekte, yalnızca marjinal maliyet oluşturmaktadır.

2. **Yanlış Negatif (FN) Sınır Vakaları — Yüzeysel Olarak Yalın Görünen Örtük Mantık Bilmeceleri:** Hiçbir teknik terim veya kod parantezi içermeyen günlük konuşma diliyle yazılmış çok kısa (8–15 kelimelik) ancak derin sağduyu veya mantıksal tuzak barındıran bilmecelerde yüzeysel entropi düşük kalabilmektedir. Bu riski minimize etmek isteyen kritik görev sistemleri için Tablo 3'te sunulan **Youden J Eşiği ($\tau_J = 0.14$)** veya **Ultra Güvenli Eşik ($\tau = 0.10$)** uygulanabilmektedir.

Geçerliliğe Yönelik Tehditler (İç, Dış ve Yapı Geçerliliği) ve Sınırlar

- **İç Geçerlilik (Internal Validity):** Öznitelik çıkarımı, winsorization sınırları, VIF elemesi, N-gram projeksiyonları, Platt kalibrasyonu, SLSQP optimizasyonu ve karar eşiği (τ^*) seçimi **yalnızca eğitim ve ayrık doğrulama kümelerinde** gerçekleştirilmiştir. Resmi test kümesi (valid.jsonl, N=10.000) hiçbir öğrenme aşamasına dahil edilmemiş ve iki küme arasındaki metin kesişiminin sıfır (Overlap = 0) olduğu doğrulanarak veri sızıntısı tehdidi tamamen ortadan kaldırılmıştır.

- **Dış Geçerlilik ve Simülasyon Sınırları:** Hedef değişken (Y = I(S_(Mixtral) ≤ 3)) küçük modelin başarısızlık riskini temsil eden bir vekildir (proxy). APGR ve maliyet simülasyonu, S_(GPT-4) = max(S_(Mixtral), 4.70) ve 17.000,00 USD vs 240,00 USD varsayımlarına dayalı bir **Koşullu Simülasyon**dur; farklı fiyatlandırma rejimlerinde ve token uzunluklarında mutlak tasarruf rakamları değişkenlik gösterebilir.

- **Yapı Geçerliliği (Construct Validity):** Yönlendirme başarımı; sıralama ayrımı (ROC-AUC, PR-AUC, K-S), kalibrasyon doğruluğu (Brier, Log-Loss, ECE), model karmaşıklık cezası (AIC, BIC, MDL) ve maliyet ekonomisi (APGR, Gain, Lift) ile çok boyutlu olarak ölçülmüştür.

SONUÇ

Bu araştırmada, Büyük Dil Modellerinin operasyonel API maliyetlerini optimize etmek amacıyla denetimli sözcüksel/semantik N-gram projeksiyonlarını, Claude Shannon'ın bilgi kuramı metriklerini ve kalibre edilmiş dörtlü karar ağacı topluluğunu birleştiren açıklanabilir bir hibrit yönlendirme mimarisi (**RouteCost-XAI**) geliştirilmiştir. UC Berkeley RouteLLM veri tabanının resmi test kümesinin tamamı (valid.jsonl, N=10.000) üzerinde yürütülen sızıntısız değerlendirmede; **Ağırlıklı Hibrit Model 0.7689 ROC-AUC, 0.3981 PR-AUC, 0.4032 F1-Skoru ve 0.0999 Brier Skoru** elde ederek 20 makine öğrenmesi modeli arasında birinci sıraya yerleşmiş ve uyarlanmış RouteLLM referans yönlendiricilerini (Matris Ayrıştırma 0.7227 AUC, SW-Ranking 0.7139 AUC) geride bırakmıştır. Ayrık doğrulama kümesinde belirlenen optimal karar eşiğinde ($\tau^* = 0.22$) simüle edilen performans farkının **%40.82'yi** (APGR) koruyarak **%82.09 net API bütçe tasarrufu** sağlayan, **0.014 ms** vektörize ağaç tahmin süresiyle çalışan ve TreeSHAP ile kararlarını açıklayan RouteCost-XAI, kurumsal yapay zeka ağ geçitleri için denetlenebilir ve ekonomik bir alternatif sunmaktadır.

Teşekkür, Finansal Destek ve Çıkar Çatışması Beyanı (Acknowledgments, Funding & Competing Interests)

- **Teşekkür (Acknowledgments):** Yazar, açık bilim ekosistemi kapsamında RouteLLM kıyaslama veri tabanını kamuya açık olarak sunan LMSYS Org ve UC Berkeley Sky Computing Lab araştırmacılarına teşekkür eder.

- **Finansal Destek (Funding):** Bu araştırma kamu, ticari veya kâr amacı gütmeyen herhangi bir finansman kuruluşundan özel bir hibe almamıştır.

- **Çıkar Çatışması Beyanı (Competing Interests):** Yazar bu makalenin içeriğiyle ilgili herhangi bir finansal veya kişisel çıkar çatışması bulunmadığını beyan eder.

- **Yazar Katkı Beyanı (CRediT Author Statement): Emin Burak Öztürk:** Kavramsallaştırma (Conceptualization), Metodoloji Tasarımı (Methodology), Yazılım ve Deneysel Doğrulama (Software & Validation), Biçimsel İstatistiksel Analiz (Formal Analysis), Veri Kürasyonu (Data Curation), Görselleştirme (Visualization) ve Makale Yazımı / İnceleme (Writing – Original Draft & Review & Editing).

Veri Erişilebilirliği ve Açık Kaynak Beyanı (Data Availability Statement)

Bu çalışmada kullanılan birincil veri seti (LMSYS / UC Berkeley RouteLLM train.jsonl ve valid.jsonl), HuggingFace açık bilim havuzunda kamuya açık olarak erişilebilir durumdadır: https://huggingface.co/datasets/routellm/gpt4_dataset/tree/main. Birleştirilmiş tekil veri seti (routellm_berkeley_dataset.csv), uçtan uca çalıştırılabilir proje kodu (RouteCost_XAI_Proje_Kodu.ipynb), tüm istatistiksel tablolar (Tablolar/Tablo1..10.csv) ve 300 DPI çözünürlüklü görseller (Grafikler/Sekil1..20.png) proje dizininde eksiksiz olarak sunulmuştur.

Yapay Zeka ve Yapay Zeka Destekli Teknolojilerin Kullanımına İlişkin Beyan

Yazar; bu çalışmanın veri analizi boru hattının kurulması, öznitelik mühendisliği hesaplamalarının doğrulanması ve görselleştirme betiklerinin hazırlanması süreçlerinde yapay zeka destekli kodlama asistanı araçlarından (Antigravity AI) pair-programming kapsamında faydalandığını beyan eder. Çalışmanın araştırma tasarımı, kavramsal çerçevesi, matematiksel modelleme prensipleri, bulguların analitik yorumlanması, sonuçların sentezlenmesi ve akademik metnin nihai onayı tamamen yazarın bilimsel sorumluluğu ve denetimi altındadır.

KAYNAKLAR

1. Ong I, Almahairi A, Wu V, Chiang WL, Wu T, Gonzalez JE, et al. RouteLLM: Learning to route LLMs with preference data. In: International Conference on Learning Representations (ICLR); 2025. Veri Seti ve Erişim: https://huggingface.co/datasets/routellm/gpt4_dataset/tree/main (Makale: https://arxiv.org/abs/2406.18665)

2. Chen L, Zaharia M, Zou J. FrugalGPT: How to use large language models while reducing cost and improving performance. Transactions on Machine Learning Research (TMLR). 2024. Erişim: https://arxiv.org/abs/2305.05176

3. Ding D, Mallick A, Wang C, Sim R, Mukherjee S, Rühle V, et al. Hybrid LLM: Cost-efficient and quality-aware query routing. In: International Conference on Learning Representations (ICLR); 2024. Erişim: https://arxiv.org/abs/2404.14618

4. Hu QJ, Bieker J, Li X, Jiang N, Keigwin B, Ranganath G, et al. RouterBench: A benchmark for multi-LLM routing system. arXiv preprint arXiv:2403.12031. 2024. Erişim: https://arxiv.org/abs/2403.12031

5. Shnitzer T, Ou A, Silva M, Soule K, Sun Y, Solomon J, et al. Large language model routing with benchmark datasets. Transactions on Machine Learning Research (TMLR). 2024. Erişim: https://arxiv.org/abs/2309.15789

6. Aggarwal P, Madaan A, Anand A, Potharaju SP, Swaminathan S, Zhou P, et al. AutoMix: Automatically mixing language models. In: Advances in Neural Information Processing Systems (NeurIPS). 2024;37. Erişim: https://arxiv.org/abs/2310.12963

7. Lu K, Yuan H, Lin R, Lin J, Yuan Z, Zhou C, et al. Routing to the expert: Efficient reward-guided ensemble of large language models. In: Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL). 2024:1964-1974. DOI: https://doi.org/10.18653/v1/2024.naacl-long.109

8. Stripelis D, Hu Z, Zhang J, Xu Z, Shah N, Jin H, et al. TensorOpera Router: A multi-model router for efficient LLM inference. arXiv preprint arXiv:2408.12320. 2024. Erişim: https://arxiv.org/abs/2408.12320

9. Chiang WL, Zheng L, Sheng Y, Angelopoulos AN, Li T, Li D, et al. Chatbot Arena: An open platform for evaluating LLMs by human preference. In: Proceedings of the 41st International Conference on Machine Learning (ICML). 2024;235:8359-8388. Erişim: https://arxiv.org/abs/2403.04132

10. Zheng L, Chiang WL, Sheng Y, Zhuang S, Wu Z, Zhuang Y, et al. Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena. In: Advances in Neural Information Processing Systems (NeurIPS). 2023;36:46595-46623. Erişim: https://arxiv.org/abs/2306.05685

11. Jiang AQ, Sablayrolles A, Roux A, Mensch A, Savary B, Bamford C, et al. Mixtral of Experts. arXiv preprint arXiv:2401.04088. 2024. Erişim: https://arxiv.org/abs/2401.04088

12. OpenAI, Achiam J, Adler S, Agarwal S, Ahmad L, Akkaya I, et al. GPT-4 Technical Report. arXiv preprint arXiv:2303.08774. 2023. Erişim: https://arxiv.org/abs/2303.08774

13. Wang S, Manning CD. Baselines and bigrams: Simple, good sentiment and topic classification. In: Proceedings of the 50th Annual Meeting of the Association for Computational Linguistics (ACL). 2012:90-94.

14. Lundberg SM, Erion G, Chen H, DeGrave A, Prutkin JM, Nair B, et al. From local explanations to global understanding with explainable AI for trees. Nature Machine Intelligence. 2020;2(1):56-67. DOI: https://doi.org/10.1038/s42256-019-0138-9

15. Lundberg SM, Lee SI. A unified approach to interpreting model predictions. In: Advances in Neural Information Processing Systems (NeurIPS). 2017;30:4765-4774. Erişim: https://arxiv.org/abs/1705.07874

16. Saeed W, Omlin C. Explainable AI (XAI): A systematic meta-survey of current challenges and future opportunities. Knowledge-Based Systems. 2023;263:110273. DOI: https://doi.org/10.1016/j.knosys.2023.110273

17. Kök İ, Okay FY, Muyanlı Ö, Özdemir S. Explainable artificial intelligence (XAI) for Internet of Things: A survey. IEEE Internet of Things Journal. 2023;10(16):14764-14779. DOI: https://doi.org/10.1109/JIOT.2023.3287678

18. Ali S, Abuhmed T, El-Sappagh S, Muhammad K, Alonso-Moral JM, Confalonieri R, et al. Explainable Artificial Intelligence (XAI): What we know and what is left to attain Trustworthy Artificial Intelligence. Information Fusion. 2023;99:101805. DOI: https://doi.org/10.1016/j.inffus.2023.101805

19. Minh D, Wang HX, Li YF, Nguyen TN. Explainable artificial intelligence: a comprehensive review. Artificial Intelligence Review. 2022;55(5):3503-3568. DOI: https://doi.org/10.1007/s10462-021-10088-y

20. Molnar C. Interpretable Machine Learning: A Guide for Making Black Box Models Explainable. 2nd ed. Munich; 2022. Erişim: https://christophm.github.io/interpretable-ml-book/

21. Niculescu-Mizil A, Caruana R. Predicting good probabilities with supervised learning. In: Proceedings of the 22nd International Conference on Machine Learning (ICML). 2005:625-632. DOI: https://doi.org/10.1145/1102351.1102430

22. Grinsztajn L, Oyallon E, Varoquaux G. Why do tree-based models still outperform deep learning on typical tabular data? In: Advances in Neural Information Processing Systems (NeurIPS). 2022;35:507-520. Erişim: https://arxiv.org/abs/2207.08815

23. Shwartz-Ziv R, Armon A. Tabular data: Deep learning is not all you need. Information Fusion. 2022;81:84-90. DOI: https://doi.org/10.1016/j.inffus.2021.11.011

24. Bentéjac C, Csörgő A, Martínez-Muñoz G. A comparative analysis of gradient boosting algorithms. Artificial Intelligence Review. 2021;54(3):1937-1967. DOI: https://doi.org/10.1007/s10946-020-09896-5

25. Mienye ID, Sun Y. A survey of ensemble learning: Concepts, algorithms, applications, and prospects. IEEE Access. 2022;10:99129-99149. DOI: https://doi.org/10.1109/ACCESS.2022.3207287

26. Ganaie MA, Hu M, Malik AK, Tanveer M, Suganthan PN. Ensemble deep learning: A review. Engineering Applications of Artificial Intelligence. 2022;115:105151. DOI: https://doi.org/10.1016/j.engappai.2022.105151

27. Silva Filho T, Song H, Perello-Nieto M, Santos-Rodriguez R, Kull M, Flach P. Classifier calibration: a survey on how to assess and improve predicted class probabilities. Machine Learning. 2023;112(9):3211-3260. DOI: https://doi.org/10.1007/s10994-023-06336-7

28. Prokhorenkova L, Gusev G, Vorobev A, Dorogush AV, Gulin A. CatBoost: unbiased boosting with categorical features. In: Advances in Neural Information Processing Systems (NeurIPS). 2018;31:6638-6648. Erişim: https://arxiv.org/abs/1706.09516

29. Ke G, Meng Q, Finley T, Wang T, Chen W, Ma W, et al. LightGBM: A highly efficient gradient boosting decision tree. In: Advances in Neural Information Processing Systems (NeurIPS). 2017;30:3146-3154.

30. Chen T, Guestrin C. XGBoost: A scalable tree boosting system. In: Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016:785-794. DOI: https://doi.org/10.1145/2939672.2939785

31. Hastie T, Tibshirani R, Friedman J. The Elements of Statistical Learning: Data Mining, Inference, and Prediction. 2nd ed. New York: Springer; 2009. DOI: https://doi.org/10.1007/978-0-387-84858-7

32. Shannon CE. A mathematical theory of communication. The Bell System Technical Journal. 1948;27(3):379-423. DOI: https://doi.org/10.1002/j.1538-7305.1948.tb01338.x

33. Cover TM, Thomas JA. Elements of Information Theory. 2nd ed. Hoboken: Wiley-Interscience; 2006. DOI: https://doi.org/10.1002/047174882X

34. Martinez J, Iglewicz B. A test for departure from normality based on a biweight estimator of scale. Biometrika. 1981;68(1):331-333. DOI: https://doi.org/10.1093/biomet/68.1.331

35. Dunn JC. Well-separated clusters and optimal fuzzy partitions. Journal of Cybernetics. 1974;4(1):95-104. DOI: https://doi.org/10.1080/01969727408546059